ĐẠI HỌC KINH TẾ QUỐC DÂN
Viện Đào tạo Tiên tiến, Chất lượng cao và POHE

BÁO CÁO BÀI TẬP LỚN
HỌC PHẦN : KHOA HỌC DỮ LIỆU

NHÓM 4

ĐỀ TÀI: Phân tích dữ liệu bán lẻ trực tuyến - Online Retail II (UCI)

Giảng viên:	**TS Trần Đức Minh**	
Thành viên:	**Đào Châu Anh**	**11240609**
	Đặng Nhật Anh	**11248116**
	Nguyễn Nam Anh	**11245516**
	Bùi Nguyễn Thảo My	**11246713**
	Nguyễn Thị Thanh Thanh	**11244570**
Lớp chuyên ngành:	**Kinh tế đầu tư CLC 66A**	

Hà Nội, 2026

MỤC LỤC

MỤC LỤC **2**
DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT **3**
GIỚI THIỆU CHUNG **4**
GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU **5**
1.1. Nguồn gốc và quy mô bộ dữ liệu Online Retail II (UCI) 5
1.2. Ý nghĩa nghiệp vụ và cấu trúc của tám trường thuộc tính 5
1.3. Kiểm tra tính nhất quán và hiện tượng chồng lấn giữa hai trang tính 7
1.4. Rà soát kiểu dữ liệu và thống kê mô tả tổng thể 7
1.5. Đánh giá hiện trạng giá trị khuyết thiếu và cơ chế phát sinh 8
1.6. Nhận diện các bất thường về nghiệp vụ và chất lượng dữ liệu khác 9
GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU **12**
2.1. Nguyên tắc thiết kế quy trình làm sạch dữ liệu có giải trình 12
2.2. Thực thi quy trình làm sạch dữ liệu qua năm bước tuần tự 13
2.3. Phát hiện giá trị ngoại lệ theo quy tắc IQR và lập luận giá đơn bán buôn 14
2.4. Kiến tạo đặc trưng thời gian và tổng kết kết quả làm sạch 16
GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU **18**
3.1. Xu hướng doanh thu theo thời gian và tính chất mùa vụ 18
3.2. Cơ cấu thị trường tiêu thụ theo quốc gia 19
3.3. So sánh phân phối giá trị đơn hàng giữa thị trường Anh và quốc tế 20
3.4. Phân bố thời điểm đặt hàng theo ngày trong tuần và giờ trong ngày 22
3.5. Phân tích nhóm sản phẩm chủ lực và tỷ lệ hủy đơn hàng 23
3.6. Mức độ tập trung doanh thu theo khách hàng và đường cong Pareto 24
GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG, KHUYẾN NGHỊ VÀ GIỚI HẠN NGHIÊN CỨU **25**
4.1. Tổng hợp câu hỏi nghiên cứu và hệ thống bằng chứng thực nghiệm 25
4.2. Các phát hiện kinh doanh trọng yếu và hàm ý quản trị 26
4.3. Hệ thống khuyến nghị có điều kiện và chỉ số đo lường hiệu quả 27
4.4. Những giới hạn về dữ liệu và phương pháp luận 28
4.5. Kết luận chung và hướng mở rộng nghiên cứu 28
DANH MỤC TÀI LIỆU THAM KHẢO **30**

DANH MỤC CÁC THUẬT NGỮ VIẾT TẮT

STT	Viết tắt	Thuật ngữ tiếng Anh đầy đủ	Ý nghĩa tiếng Việt trong bối cảnh nghiên cứu
1	AOV	Average Order Value	Giá trị trung bình trên mỗi đơn đặt hàng
2	B2B	Business to Business	Mô hình giao dịch thương mại giữa doanh nghiệp với doanh nghiệp (bán buôn)
3	B2C	Business to Consumer	Mô hình giao dịch thương mại giữa doanh nghiệp với người tiêu dùng (bán lẻ)
4	EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu bằng thống kê mô tả và trực quan hóa
5	EIRE	Ireland	Mã quốc gia Cộng hòa Ireland trong hệ thống kế toán của doanh nghiệp
6	GBP (£)	Great Britain Pound	Đồng Bảng Anh - đơn vị tiền tệ hạch toán trong toàn bộ bộ dữ liệu
7	IQR	Interquartile Range	Khoảng tứ phân vị (hiệu số giữa phân vị thứ 75 và phân vị thứ 25)
8	KPI	Key Performance Indicator	Chỉ số đo lường và đánh giá hiệu quả hoạt động cốt lõi
9	SKU	Stock Keeping Unit	Đơn vị lưu kho định danh riêng biệt cho từng mặt hàng (StockCode)
10	UCI	University of California, Irvine	Kho lưu trữ dữ liệu học máy chuẩn quốc tế của Đại học California, Irvine
11	UK	United Kingdom	Vương quốc Liên hiệp Anh và Bắc Ireland (thị trường nội địa của doanh nghiệp)

Bảng 0.1. Các từ viết tắt và thuật ngữ chuyên môn trong báo cáo

GIỚI THIỆU CHUNG

1. Bối cảnh thực tiễn và mục tiêu nghiên cứu

Trong nền kinh tế số hiện đại, sự phát triển mạnh mẽ của thương mại điện tử đã chuyển hóa từng giao dịch mua bán thành nguồn dữ liệu chiến lược phản ánh hành vi tiêu dùng, nhịp điệu mùa vụ và cấu trúc thị trường. Đối với các doanh nghiệp bán lẻ và bán buôn trực tuyến chuyên kinh doanh mặt hàng quà tặng, vật phẩm trang trí tại Vương quốc Anh, việc phân tích dữ liệu lịch sử đóng vai trò quyết định trong dự báo nhu cầu, điều phối kho vận và kiểm soát rủi ro hủy trả đơn hàng. Tuy nhiên, dữ liệu tác nghiệp thực tế thường pha trộn giữa hóa đơn bán hàng với bút toán hủy trả, điều chỉnh công nợ, phụ phí bưu điện, chiết khấu thương mại, đồng thời tồn tại hiện tượng khuyết thiếu mã định danh khách hàng vãng lai và chồng lấn bản ghi giữa các kỳ kế toán. Xuất phát từ thực tiễn đó, báo cáo thực hiện phân tích bộ dữ liệu Online Retail II (UCI) trên môi trường Google Colab nhằm xây dựng một quy trình khoa học dữ liệu minh bạch và có khả năng tái lập cao: từ khảo sát hiện trạng dữ liệu gốc, tiền xử lý có giải trình nghiệp vụ, phân tích trực quan hóa khám phá đến đề xuất các khuyến nghị quản trị có điều kiện.

2. Hệ thống câu hỏi nghiên cứu, phạm vi và kết cấu báo cáo

Để chuyển hóa hơn một triệu bản ghi giao dịch thô thành hệ thống bằng chứng thực nghiệm phục vụ ra quyết định, nghiên cứu tập trung giải quyết năm câu hỏi nghiên cứu trọng tâm bám sát tệp chương trình thực nghiệm Google Colab: (1) Doanh thu của doanh nghiệp biến động như thế nào theo thời gian và thể hiện tính chất mùa vụ ra sao giữa giai đoạn cao điểm cuối năm từ tháng 9 đến tháng 11 so với các tháng còn lại; (2) Cơ cấu thị trường tiêu thụ phân bổ như thế nào giữa Vương quốc Anh và các quốc gia xuất khẩu hàng đầu; (3) Quy mô giá trị đơn hàng trung bình và trung vị khác biệt ra sao giữa thị trường nội địa Anh và thị trường quốc tế; (4) Lưu lượng hóa đơn phân bố như thế nào theo các ngày làm việc trong tuần và các khung giờ trong ngày, đồng thời nhóm mặt hàng nào đóng góp chủ lực vào doanh thu và thực trạng hủy đơn diễn ra ra sao; (5) Doanh thu tập trung vào nhóm khách hàng lớn ở mức độ nào trên đường cong tích lũy Pareto.

Về phạm vi nghiên cứu, báo cáo khảo sát toàn bộ chuỗi giao dịch của bộ dữ liệu Online Retail II kéo dài từ ngày 01/12/2009 đến ngày 09/12/2011 trên hai trang tính kế toán bằng ngôn ngữ Python (sử dụng các thư viện Pandas, NumPy, Matplotlib và Seaborn). Ngoài phần Mở đầu, Danh mục thuật ngữ viết tắt và Tài liệu tham khảo, nội dung chính của báo cáo được cấu trúc chặt chẽ theo đúng bốn giai đoạn của đề bài: Giai đoạn 1 trình bày thu thập và đánh giá chất lượng dữ liệu ban đầu; Giai đoạn 2 giải trình quy trình tiền xử lý, làm sạch dữ liệu và đánh giá ngoại lệ IQR; Giai đoạn 3 phân tích khám phá và trực quan hóa sáu khía cạnh kinh doanh; và Giai đoạn 4 tổng hợp bằng chứng, đề xuất khuyến nghị quản trị kèm chỉ số KPI và phân tích giới hạn nghiên cứu.

GIAI ĐOẠN 1: THU THẬP VÀ ĐÁNH GIÁ DỮ LIỆU BAN ĐẦU

1.1. Nguồn gốc và quy mô bộ dữ liệu Online Retail II (UCI)

Bộ dữ liệu sử dụng trong nghiên cứu này là Online Retail II, có nguồn gốc từ Kho lưu trữ Học máy thuộc Đại học California, Irvine (UCI Machine Learning Repository) và được phân phối rộng rãi trên nền tảng khoa học dữ liệu Kaggle. Đây là tập dữ liệu giao dịch thực tế của một doanh nghiệp bán lẻ trực tuyến có trụ sở tại Vương quốc Anh, hoạt động theo mô hình không cửa hàng vật lý và tập trung kinh doanh các dòng sản phẩm quà tặng độc đáo dành cho mọi lứa tuổi. Tệp dữ liệu gốc được lưu trữ dưới định dạng bảng tính Microsoft Excel mang tên online_retail_II.xlsx, bao gồm hai trang tính độc lập tương ứng với hai giai đoạn kế toán liên tiếp là Year 2009-2010 và Year 2010-2011.

Khi tiến hành nạp toàn bộ tệp bảng tính vào môi trường Google Colab bằng hàm đọc dữ liệu của thư viện Pandas, đồng thời ép kiểu chuỗi ngay từ đầu đối với hai trường mã định danh là mã hóa đơn (Invoice) và mã sản phẩm (StockCode) nhằm ngăn chặn hiện tượng tự động cắt bỏ ký tự chữ cái, kết quả kiểm tra kích thước cho thấy quy mô đồ sộ của từng trang tính. Cụ thể, trang tính đầu tiên (Year 2009-2010) chứa 525.461 dòng bản ghi với 8 cột thuộc tính, phản ánh các giao dịch diễn ra từ ngày 01/12/2009 đến ngày 09/12/2010. Trang tính thứ hai (Year 2010-2011) chứa 541.910 dòng bản ghi với 8 cột thuộc tính tương đồng, ghi nhận hoạt động mua bán từ ngày 01/12/2010 đến ngày 09/12/2011. Tổng cộng sau khi hợp nhất hai trang tính theo chiều dọc bằng hàm concat của thư viện Pandas, tập dữ liệu thô ban đầu (df_raw) đạt quy mô lên tới 1.067.371 dòng bản ghi và 8 cột thuộc tính.

1.2. Ý nghĩa nghiệp vụ và cấu trúc của tám trường thuộc tính

Để xây dựng quy trình tiền xử lý và phân tích chuẩn xác, bước nền tảng là phải xác định rõ đơn vị quan sát của bảng dữ liệu. Trong bộ dữ liệu Online Retail II, mỗi dòng bản ghi không đại diện cho một hóa đơn tổng hợp hay một khách hàng riêng lẻ, mà đại diện cho một dòng chi tiết mặt hàng nằm trong một hóa đơn cụ thể. Một hóa đơn mua hàng hoàn chỉnh thường bao gồm nhiều dòng bản ghi có cùng mã hóa đơn, cùng mã khách hàng và cùng thời điểm thanh toán nhưng khác nhau về mã sản phẩm, tên mô tả, số lượng mua và đơn giá. Ví dụ, ngay tại 5 dòng bản ghi đầu tiên của hóa đơn số 489434 lập lúc 07 giờ 45 phút ngày 01/12/2009 của khách hàng mã số 13085 tại Vương quốc Anh, người mua đã đặt đồng thời các mặt hàng quả cầu thủy tinh Giáng sinh 20 bóng đèn (12 sản phẩm, giá 6,95 Bảng), đèn hoa anh đào hồng và trắng (mỗi loại 12 sản phẩm, giá 6,75 Bảng), khung đĩa nhạc 7 inch (48 sản phẩm, giá 2,10 Bảng) và hộp nfi trang gốm hình dâu tây (24 sản phẩm, giá 1,25 Bảng). Cấu trúc và ý nghĩa của cả tám trường thuộc tính được tổng hợp chi tiết trong Bảng 1.2.

Tên thuộc tính	Kiểu dữ liệu gốc	Ý nghĩa nghiệp vụ và đặc điểm nhận diện trong hệ thống
Invoice	Chuỗi ký tự (object)	Mã số định danh hóa đơn gồm 6 chữ số nguyên. Nếu mã bắt đầu bằng ký tự C thì đó là hóa đơn hủy hoặc trả hàng; bắt đầu bằng ký tự A là bút toán điều chỉnh nợ xấu.

StockCode	Chuỗi ký tự (object)	Mã định danh duy nhất của từng mặt hàng hoặc dịch vụ lưu kho, thông thường gồm 5 chữ số nguyên hoặc 5 chữ số kèm theo hậu tố chữ cái phân loại mẫu mã, màu sắc.
Description	Chuỗi ký tự (object)	Tên mô tả thương mại bằng tiếng Anh của sản phẩm tương ứng với mã lưu kho, giúp nhận diện chủng loại hàng hóa trong danh mục kinh doanh (1.062.989 dòng khác rỗng).
Quantity	Số nguyên (int64)	Số lượng đơn vị sản phẩm được đặt mua hoặc hoàn trả trên từng dòng hóa đơn. Giá trị âm phản ánh nghiệp vụ trả hàng, hủy đơn hoặc xuất hủy kiểm kê kho.
InvoiceDate	Thời gian (datetime64)	Dấu thời gian ghi nhận chính xác ngày, tháng, năm, giờ và phút phát sinh giao dịch lập hóa đơn trên hệ thống máy chủ của doanh nghiệp.
Price	Số thực (float64)	Đơn giá bán của một đơn vị sản phẩm tính bằng đồng Bảng Anh (GBP - £) chưa bao gồm thuế giá trị gia tăng và chi phí vận chuyển riêng.
Customer ID	Số thực (float64)	Mã số định danh khách hàng gồm 5 chữ số nguyên dành cho người mua có đăng ký tài khoản (824.364 dòng khác rỗng). Đang lưu dạng float64 do có giá trị khuyết thiếu.
Country	Chuỗi ký tự (object)	Tên quốc gia hoặc vùng lãnh thổ nơi khách hàng cư trú hoặc đăng ký địa chỉ nhận hàng, phục vụ phân tích cơ cấu thị trường nội địa và xuất khẩu.

Bảng 1.2. Mô tả cấu trúc, kiểu dữ liệu và ý nghĩa nghiệp vụ của 8 thuộc tính trong bộ dữ liệu
Nguồn: Tổng hợp từ tài liệu đặc tả UCI Machine Learning Repository và Ô lệnh 4, 13.

1.3. Kiểm tra tính nhất quán và hiện tượng chồng lấn giữa hai trang tính

Trước khi tiến hành gộp hai trang tính thành một bảng dữ liệu duy nhất, một nguyên tắc bắt buộc trong khoa học dữ liệu là phải kiểm chứng tính tương thích về mặt cấu trúc, rà soát ranh giới thời gian giữa hai tệp và đánh giá mức độ liên thông của các thực thể định danh xuyên suốt hai niên độ. Kết quả thực thi kiểm tra tự động trên Google Colab khẳng định cả hai trang tính Year 2009-2010 và Year 2010-2011 đều có danh sách tên cột trùng khớp tuyệt đối (True) và kiểu dữ liệu của từng cột tương ứng hoàn toàn đồng nhất (True). Nhờ đó, phép nối dọc hai bảng dữ liệu không gây ra hiện tượng lệch cột hay phát sinh cột rỗng ngoài ý muốn.

Tuy nhiên, phép kiểm tra ranh giới thời gian tại Ô lệnh 8 đã phát hiện một vấn đề kỹ thuật hết sức quan trọng: hai trang tính tồn tại một khoảng thời gian chồng lấn kéo dài đúng 9 ngày, bắt đầu từ ngày 01/12/2010 đến hết ngày 09/12/2010. Khi lọc riêng các bản ghi rơi vào khoảng thời gian từ ngày 01/12/2010 đến ngày 09/12/2010 ở từng trang tính, trang tính thứ nhất ghi nhận đúng 22.523 dòng giao dịch và trang tính thứ hai cũng ghi nhận đúng 22.523 dòng giao dịch, với tổng cộng 1.088 mã hóa đơn xuất hiện đồng thời ở cả hai trang tính. Phát hiện này cho thấy khi nhà cung cấp dữ liệu trích xuất bảng tính cho niên độ thứ hai từ ngày 01/12/2010, toàn bộ giao dịch của 9 ngày đầu tháng 12/2010 vốn đã nằm ở cuối trang tính thứ nhất lại tiếp tục được đưa vào đầu trang tính thứ hai. Nếu người phân tích chỉ ghép nối cơ học hai trang tính mà không thực hiện bước khử trùng lặp ở Giai đoạn 2, toàn bộ doanh thu và sản lượng của 9 ngày cao điểm đầu tháng 12/2010 sẽ bị tính gấp đôi, làm méo mó nghiêm trọng bức tranh tăng trưởng giữa hai năm.

Bên cạnh việc phát hiện vùng chồng lấn thời gian, nhóm nghiên cứu cũng tiến hành kiểm tra tính liên tục của khóa định danh khách hàng (Customer ID) và khóa định danh sản phẩm (StockCode) giữa hai kỳ kế toán tại Ô lệnh 9. Kết quả đối chiếu tập hợp cho thấy trang tính thứ nhất có 4.383 khách hàng định danh, trang tính thứ hai có 4.372 khách hàng định danh, và có tới 2.813 khách hàng xuất hiện xuyên suốt ở cả hai năm (chiếm hơn 64 phần trăm quy mô tệp khách hàng của mỗi năm). Tương tự, trên phương diện danh mục hàng hóa, trang tính thứ nhất kinh doanh 4.632 mã sản phẩm, trang tính thứ hai kinh doanh 4.070 mã sản phẩm, trong đó có 3.397 mã sản phẩm được duy trì bán liên tục qua cả hai niên độ. Sự hiện diện ổn định của 2.813 khách hàng và 3.397 mã sản phẩm qua hai năm chứng minh hệ thống mã định danh được duy trì nhất quán, cho phép hợp nhất hai trang tính thành một chuỗi lịch sử dài hạn liên tục sau khi đã loại bỏ phần bản ghi trùng lặp.

1.4. Rà soát kiểu dữ liệu và thống kê mô tả tổng thể

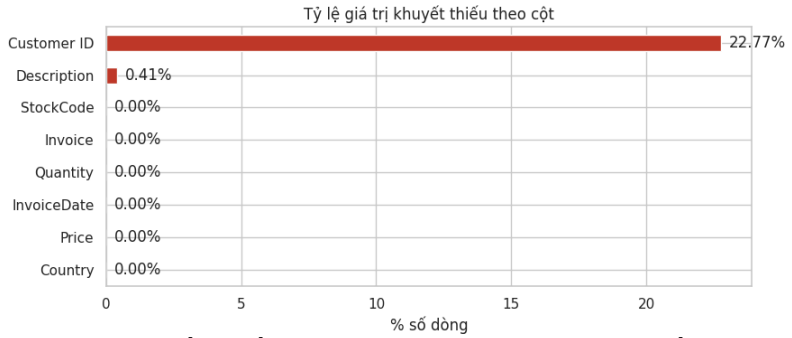
Sau khi hợp nhất hai trang tính thành bảng dữ liệu df_raw gồm 1.067.371 dòng và 8 cột (chiếm hơn 65,1 MB bộ nhớ RAM), nhóm nghiên cứu thực hiện rà soát tổng thể kiểu dữ liệu và tính toán các đại lượng thống kê mô tả trên toàn bộ tập dữ liệu gốc tại Ô lệnh 13 và 14. Kết quả kiểm tra cấu trúc cho thấy có 6 trên 8 cột đạt trạng thái đầy đủ 1.067.371 giá trị khác rỗng, riêng cột mô tả sản phẩm (Description) chỉ có 1.062.989 giá trị hợp lệ và cột mã khách hàng (Customer ID) chỉ có 824.364 giá trị hợp lệ. Đáng chú ý, cột Customer ID đang được trình biên dịch lưu trữ dưới dạng số thực dấu phẩy động (float64) với giá trị trung bình là 15.324,64, cực tiểu 12.346,00, cực đại 18.287,00 và độ lệch chuẩn 1.697,46. Về mặt bản chất, mã khách hàng là ký hiệu định danh rời rạc chứ không phải đại lượng đo lường toán học, nhưng do trong cột tồn tại các ô khuyết thiếu (NaN) nên thư viện đọc dữ liệu tự động ép kiểu số

nguyên sang số thực. Do đó, việc chuyển đổi trường này về kiểu chuỗi ký tự định danh là yêu cầu bắt buộc trong giai đoạn tiền xử lý.

Xét các đại lượng thống kê mô tả của hai biến định lượng kinh tế là số lượng (Quantity) và đơn giá (Price) trên tập dữ liệu gốc 1.067.371 bản ghi, có thể nhận thấy ngay hai dấu hiệu bất thường nghiêm trọng về mặt phân phối toán học và nghiệp vụ kế toán. Thứ nhất, cả biến số lượng và biến đơn giá đều xuất hiện các giá trị cực tiểu mang dấu âm vô cùng lớn: số lượng thấp nhất chạm mức âm 80.995,00 đơn vị, trong khi đơn giá thấp nhất chạm mức âm 53.594,36 Bảng Anh. Trong thương mại thực tế, không thể tồn tại một giao dịch bán hàng thông thường có số lượng âm hoặc giá bán âm; đây chính là dấu hiệu của các giao dịch hủy đơn, hoàn trả hàng hóa, xuất hủy hàng hỏng hoặc các bút toán điều chỉnh xóa nợ xấu trên hệ thống kế toán. Thứ hai, sự chênh lệch khổng lồ giữa giá trị trung bình và các mốc phân vị phản ánh hiện tượng phân phối lệch phải cực mạnh: biến Quantity có phân vị 25 phần trăm là 1,00 đơn vị, trung vị (phân vị 50 phần trăm) chỉ ở mức 3,00 đơn vị và phân vị 75 phần trăm ở mức10,00 đơn vị, nhưng giá trị trung bình bị kéo vọt lên mức 9,94 đơn vị kèm độ lệch chuẩn lên tới 172,71 do sự xuất hiện của giá trị cực đại 80.995,00 đơn vị. Tương tự, biến Price có phân vị 25 phần trăm là 1,25 Bảng Anh, trung vị chỉ đạt 2,10 Bảng Anh và phân vị 75 phần trăm đạt 4,15 Bảng Anh, nhưng giá trị cực đại lên tới 38.970,00 Bảng Anh đã kéo trung bình cộng lên 4,65 Bảng Anh với độ lệch chuẩn 123,55.

1.5. Đánh giá hiện trạng giá trị khuyết thiếu và cơ chế phát sinh

Khảo sát chuyên sâu về hiện trạng dữ liệu khuyết thiếu là bước then chốt nhằm lựa chọn chiến lược xử lý phù hợp, tránh làm biến dạng cấu trúc mẫu nghiên cứu. Kết quả thống kê tại Ô lệnh 17 và trực quan hóa trên Hình 1.5 cho thấy trong tổng số 8 trường thuộc tính, có 6 trường (StockCode, Invoice, Quantity, InvoiceDate, Price, Country) đạt tỷ lệ điền đầy đủ 100 phần trăm (0,00 phần trăm khuyết thiếu), trong khi hiện tượng khuyết thiếu tập trung hoàn toàn ở hai trường là Customer ID (thiếu 243.007 dòng, tương ứng 22,77 phần trăm tổng số bản ghi) và Description (thiếu 4.382 dòng, tương ứng 0,41 phần trăm tổng số bản ghi).



Hình 1.5. Tỷ lệ giá trị khuyết thiếu theo cột trong tập dữ liệu gốc (12/2009 – 12/2011)

Quan sát Hình 1.5, có thể thấy rõ sự chênh lệch về mức độ khuyết thiếu giữa các trường dữ liệu khi cột Customer ID chiếm tới 22,77 phần trăm tổng số dòng bị rỗng, tạo thành thanh ngang màu đỏ nổi bật vượt xa toàn bộ các trường còn lại. Để kiểm tra xem việc thiếu hụt hơn 243 nghìn mã khách hàng này có xảy ra hoàn toàn ngẫu nhiên hay bắt nguồn từ cơ chế vận hành đặc thù, nhóm nghiên cứu đã tiến hành phân tổ tỷ lệ khuyết thiếu theo khu vực địa lý (Vương quốc Anh so với ngoài Vương quốc Anh) so sánh đơn giá trung vị giữa nhóm bản ghi có mã khách hàng với nhóm bản ghi bị khuyết mã khách hàng tại Ô lệnh 18.

Kết quả thực nghiệm chứng minh rằng hiện tượng khuyết thiếu Customer ID hoàn toàn không mang tính ngẫu nhiên. Cụ thể, tại thị trường nội địa Vương quốc

Anh, tỷ lệ dòng giao dịch không có mã khách hàng lên tới 24,46 phần trăm, cao gấp hơn 7 lần so với mức chỉ 3,46 phần trăm tại các thị trường quốc tế ngoài nước Anh. Đồng thời, đơn giá trung vị của các dòng giao dịch bị thiếu mã khách hàng đạt 3,29 Bảng Anh, cao hơn đáng kể so với mức đơn giá trung vị 1,95 Bảng Anh của nhóm giao dịch có định danh khách hàng đầy đủ. Sự kết hợp của hai bằng chứng này phản ánh rõ cơ chế nghiệp vụ: các đối tác quốc tế hầu hết là doanh nghiệp nhập khẩu sỉ nên bắt buộc phải đăng ký tài khoản định danh để làm thủ tục thanh toán và vận chuyển xuyên biên giới (nên hưởng mức đơn giá sỉ thấp hơn), trong khi một bộ phận lớn người tiêu dùng cá nhân tại nội địa Anh thực hiện mua lẻ trực tiếp trên cổng thanh toán vãng lai mà không cần đăng nhập tài khoản (chấp nhận mức giá bán lẻ cao hơn). Từ phát hiện cốt lõi này, nhóm nghiên cứu xác lập nguyên tắc xử lý ba điểm đối với trường Customer ID: thứ nhất, tuyệt đối không nội suy hay điền thế bằng giá trị trung bình hay yếu vị vì mã định danh không mang ý nghĩa đại lượng số học; thứ hai, tuyệt đối không xóa bỏ 243.007 dòng này khi phân tích tổng doanh thu, xu hướng mùa vụ, thị trường và sản phẩm vì việc xóa bỏ sẽ làm mất gần một phần tư quy mô giao dịch và gây chệch mẫu nghiên cứu về phía khách hàng bán buôn; thứ ba, chỉ tách riêng tập con có đầy đủ mã khách hàng khi thực hiện các phân tích đòi hỏi gom nhóm ở cấp độ từng khách hàng như đường cong tập trung Pareto hay giá trị đơn hàng theo tệp khách định danh. Đối với 4.382 dòng bản ghi bị khuyết thiếu tên mô tả sản phẩm (Description), kiểm tra chéo với cột đơn giá ở Ô lệnh 29 cho thấy đúng 100,0 phần trăm các dòng thiếu Description trong tập dữ liệu gốc đều có đơn giá bằng 0 (Price = 0). Đây thực chất là các bút toán ghi chú nội bộ hoặc điều chỉnh tồn kho không mang giá trị thương mại, nên chúng sẽ tự động bị loại bỏ hoàn toàn khi áp dụng bộ lọc giá lại các giao dịch có đơn giá dương ở Giai đoạn 2.

1.6. Nhận diện các bất thường về nghiệp vụ và chất lượng dữ liệu khác

Không dừng lại ở vấn đề giá trị khuyết thiếu, quá trình kiểm toán chất lượng dữ liệu sâu hơn trên tập df_raw tại Ô lệnh 21, 22 và 23 đã làm lộ diện toàn bộ các nhóm bản ghi bất thường cần được bóc tách và xử lý bài bản trước khi phân tích. Như thống kê tổng hợp tại Bảng 1.2, toàn bộ tập dữ liệu chứa 34.335 dòng trùng lặp hoàn toàn trên cả 8 trường thuộc tính (chiếm 3,22 phần trăm tổng số bản ghi), bao gồm cả toàn bộ phần giao dịch bị nhân đôi do hiện tượng chồng lấn 9 ngày đầu tháng 12/2010 giữa hai trang tính cùng các thao tác ghi nhận đúp của hệ thống. Bên cạnh đó, tập dữ liệu ghi nhận 19.494 dòng thuộc các hóa đơn hủy trả (có mã Invoice bắt đầu bằng chữ cái C) và 6 dòng thuộc các hóa đơn điều chỉnh xóa nợ xấu (có mã Invoice bắt đầu bằng chữ cái A). Xét trên góc độ giá trị định lượng, có 22.950 dòng có số lượng nhỏ hơn hoặc bằng 0 và 6.207 dòng có đơn giá nhỏ hơn hoặc bằng 0.

Một phát hiện quan trọng khác nằm ở trường mã lưu kho StockCode: thông qua biểu thức chính quy lọc các mã chỉ bao gồm chữ cái hoặc bắt đầu bằng tiền tố đặc biệt như DCGS và gift, nhóm nghiên cứu phát hiện 5.787 dòng bản ghi không phải là sản phẩm thương mại vật lý mà là các khoản phí dịch vụ, chiết khấu hoặc bút toán kế toán nội bộ. Đứng đầu danh sách 12 mã phi sản phẩm xuất hiện nhiều nhất là mã phí bưu điện vận chuyển quốc tế POST với 2.122 dòng (mô tả POSTAGE), tiếp theo là phí vận chuyển qua cổng trực tuyến DOT với 1.446 dòng (DOTCOM POSTAGE), bút toán nhập tay thủ công M với 1.421 dòng (Manual), khoản chiết khấu thương mại D với 177 dòng (Discount), hàng mẫu thử nghiệm S với 104 dòng (SAMPLES), phí dịch vụ ngân hàng BANK CHARGES với 102 dòng, bút toán điều chỉnh hệ thống ADJUST với 67 dòng, phí sàn thương mại điện tử AMAZONFEE với 43 dòng, cùng các mã phụ trợ DCGS0058 (31 dòng), phiếu quà tặng gift_0001_30 (29 dòng), gift_0001_20 (29 dòng) và DCGSSGIRL (25 dòng). Nếu giá nguyên 5.787 dòng này

trong bảng phân tích doanh thu sản phẩm, các khoản phí bưu điện và phí sàn có giá trị hàng nghìn Bảng sẽ bị xếp nhầm vào danh sách mặt hàng bán chạy nhất, làm sai lệch hoàn toàn cơ cấu danh mục hàng hóa của doanh nghiệp. Ngoài ra, khi kiểm tra tính nhất quán giữa mã định danh sản phẩm (StockCode) và tên mô tả sản phẩm (Description) trên tổng số 4.950 mã StockCode có tên mô tả, kết quả cho thấy có tới 1.232 mã StockCode (chiếm 24,89 phần trăm) bị gắn với nhiều hơn một tên mô tả khác nhau. Điển hình như mã sản phẩm của mặt hàng túi cỡ lớn họa tiết cú mèo (JUMBO BAG OWLS) có 1.372 dòng ghi đúng tên thương mại chuẩn, nhưng lại xen lẫn các dòng có nội dung ghi chú kiểm kho như missing (1 dòng), wrongly marked 23343 in box (1 dòng), wrongly coded-23343 (1 dòng) và found (1 dòng). Hiện tượng này đòi hỏi phải có bước đồng bộ hóa mỗi mã StockCode về một tên mô tả phổ biến nhất (mode) ở Giai đoạn 2.

Nhóm vấn đề chất lượng dữ liệu và nghiệp vụ đặc biệt	Số lượng bản ghi / mã	Tỷ lệ / Quy mô	Định hướng xử lý tại Giai đoạn 2
Khuyết thiếu mã khách hàng (Customer ID = NaN)	243.007 dòng	22,77% tổng số dòng	Giá lại trong df (doanh thu); tách riêng df_cust (khách hàng)
Khuyết thiếu mô tả sản phẩm (Description = NaN)	4.382 dòng	0,41% (100% có Price = 0)	Tự động bị loại khi lọc Price > 0; điền mode dự phòng
Dòng bản ghi trùng lặp hoàn toàn trên 8 cột	34.335 dòng	3,22% (gồm 1.088 đơn chồng lấn)	Loại bỏ triệt để bằng hàm drop_duplicates()
Hóa đơn hủy hoặc trả hàng (Invoice bắt đầu bằng C)	19.494 dòng	1,83% (8.292 hóa đơn sau khử trùng)	Tách sang bảng riêng df_cancel để phân tích tỷ lệ hủy
Hóa đơn điều chỉnh nợ xấu (Invoice bắt đầu bằng A)	6 dòng	0,0006% tổng số dòng	Loại bỏ khỏi bảng giao dịch bán hàng thương mại
Dòng có số lượng không dương (Quantity <= 0)	22.950 dòng	2,15% tổng số dòng	Lọc giá lại các giao dịch có Quantity > 0
Dòng có đơn giá bán không dương (Price <= 0)	6.207 dòng	0,58% tổng số dòng	Lọc giá lại các giao dịch có Price > 0
Mã StockCode phi sản phẩm (POST, DOT, M, D, S...)	5.787 dòng	0,54% (53 mã phi sản phẩm)	Loại bỏ bằng biểu thức chính quy nhận diện mã đặc biệt

Một mã StockCode gắn với nhiều tên Description	1.232 mã SKU	24,89% trên 4.950 mã có tên	Chuẩn hóa mỗi mã StockCode về tên xuất hiện nhiều nhất (mode)

Bảng 1.6. Tổng hợp toàn diện các vấn đề chất lượng dữ liệu phát hiện trong tập dữ liệu gốc (df_raw)

GIAI ĐOẠN 2: TIỀN XỬ LÝ VÀ LÀM SẠCH DỮ LIỆU

2.1. Nguyên tắc thiết kế quy trình làm sạch dữ liệu có giải trình

Trên cơ sở những vấn đề chất lượng dữ liệu đã được bóc tách định lượng tại Giai đoạn 1, Giai đoạn 2 tập trung thiết kế và thực thi một quy trình tiền xử lý dữ liệu có tính giải trình cao. Thay vì xóa bỏ cơ học mọi bản ghi có dấu hiệu khác biệt, mỗi thao tác can thiệp vào dữ liệu trong báo cáo này đều tuân thủ chặt chẽ cấu trúc lập luận bốn thành phần: xác định rõ vấn đề hiện hữu, lựa chọn phương pháp kỹ thuật xử lý tương ứng, giải trình lý do nghiệp vụ đằng sau quyết định đó, và đánh giá đầy đủ tác động hay giới hạn của bước xử lý đối với phạm vi kết luận phân tích.

Một lưu ý phương pháp luận đặc biệt quan trọng được đặt ra ngay từ đầu Giai đoạn 2 là cách thức xử lý các hóa đơn hủy trả. Trong hệ thống kế toán của doanh nghiệp, các hóa đơn bắt đầu bằng ký tự C ghi nhận số lượng âm để phản ánh nghiệp vụ hủy đơn hoặc hoàn trả hàng. Tuy nhiên, bộ dữ liệu không cung cấp khóa tham chiếu trực tiếp liên kết từng hóa đơn hủy với hóa đơn mua hàng gốc ban đầu, đồng thời một số hóa đơn hủy phát sinh vào đầu tháng 12/2009 có thể bắt nguồn từ các đơn hàng mua từ tháng 11/2009 nằm ngoài phạm vi thu thập dữ liệu. Do đó, việc tách riêng các hóa đơn hủy sang một bảng độc lập (df_cancel) vừa giúp làm sạch bảng doanh thu bán hàng dương (df), vừa bảo toàn dữ liệu để tính toán các chỉ số cảnh báo về tỷ lệ hủy đơn theo khu vực thị trường ở Giai đoạn 3.

Vấn đề chất lượng dữ liệu	Phương pháp kỹ thuật xử lý	Cơ sở lý giải nghiệp vụ và lưu ý phạm vi phân tích
Bản ghi trùng lặp hoàn toàn (34.335 dòng)	Thực thi hàm drop_duplicates() và chuẩn hóa kiểu chuỗi cho các cột định danh	Loại bỏ hoàn toàn hiện tượng nhân đôi giao dịch do chồng lấn 9 ngày giữa 2 trang tính; chấp nhận giả định rằng các dòng trùng hệt nhau trong cùng một hóa đơn là bản ghi đúp.
Hóa đơn hủy bắt đầu bằng C và điều chỉnh nợ A	Tách riêng các hóa đơn C sang bảng df_cancel (19.104 dòng); loại bỏ 6 dòng hóa đơn A	Phân tích riêng quy mô và tỷ lệ hủy đơn mà không làm nhiễu dòng doanh thu bán hàng dương; loại bỏ các bút toán xóa nợ xấu kế toán không phản ánh tiêu thụ hàng hóa.
Mã StockCode phi sản phẩm (53 mã đặc biệt)	Dùng biểu thức chính quy lọc và loại bỏ các mã chỉ gồm chữ cái hoặc bắt đầu bằng DCGS, GIFT	Tách bạch doanh thu bán hàng thực chất khỏi các khoản thu hộ phí bưu điện (POST, DOT), phí sàn (AMAZONFEE), chiết khấu (D) và bút toán nhập tay (M).
Bản ghi có Quantity <= 0 hoặc Price <= 0	Áp dụng bộ lọc giá lại các dòng thỏa mãn đồng thời Price > 0 và Quantity > 0 (loại 5.936 dòng)	Bảo đảm bảng phân tích doanh thu chỉ chứa các giao dịch thương mại có giá trị kinh tế dương, loại bỏ các dòng xuất hủy kho hoặc hàng tặng giá bằng 0.
Thiếu hoặc	Áp dụng quy tắc ánh xạ mỗi mã	Đồng bộ hóa 1.232 mã sản phẩm bị phân

không nhất quán trường Description	StockCode về tên mô tả phổ biến nhất (mode) của chính mã đó	mảnh tên gọi về một tên chuẩn duy nhất mà không tự ý suy đoán chéo giữa các mã lưu kho khác nhau.
Khuyết thiếu trường Customer ID (22,77%)	Giá nguyên trong bảng df để phân tích doanh thu tổng thể; tách bảng df_cust cho phân tích khách hàng	Mã khách hàng là định danh rời rạc nên không thể điền bằng trung bình hay yếu vị; giá lại trong df để không đánh mất doanh thu của nhóm khách lẻ vãng lai.
Điểm ngoại lệ (Outliers) trên Quantity, Price	Dùng khoảng tứ phân vị IQR để phát hiện và đối chiếu với df_cancel, không xóa tự động hàng loạt	Phân phối giao dịch bán buôn tự nhiên lệch phải rất mạnh; các đơn sỉ hợp lệ đóng góp tới 50,2% doanh thu nên việc xóa máy móc theo IQR sẽ làm sai lệch nghiêm trọng kết quả.

Bảng 2.1. Khung tổng hợp vấn đề chất lượng dữ liệu, phương pháp xử lý và cơ sở lý giải

2.2. Thực thi quy trình làm sạch dữ liệu qua năm bước tuần tự

Quy trình làm sạch dữ liệu trên Google Colab được triển khai tuần tự qua năm bước kỹ thuật chặt chẽ tại các Ô lệnh 26 đến 29, bắt đầu từ bản sao của tập dữ liệu gốc gồm 1.067.371 dòng. Ở Bước 1, nhóm nghiên cứu thực hiện loại bỏ toàn bộ các dòng bản ghi trùng lặp hoàn toàn bằng phương thức drop_duplicates(). Kết quả thực thi đã xóa bỏ chính xác 34.335 dòng trùng lặp, tương đương 3,22 phần trăm tổng số bản ghi ban đầu, đưa quy mô tập dữ liệu về mức1.033.036 dòng và giải quyết triệt để hiện tượng đếm trùng 1.088 hóa đơn trong vùng chồng lấn từ ngày 01/12/2010 đến ngày 09/12/2010. Ngay trong bước này, các trường định danh được chuẩn hóa kiểu dữ liệu đồng bộ: trường Invoice và StockCode được chuyển về kiểu chuỗi ký tự viết hoa và cắt bỏ khoảng trắng thừa ở hai đầu; trường Customer ID được chuyển từ kiểu số thực sang kiểu số nguyên có hỗ trợ giá trị rỗng (Int64) rồi ép sang kiểu chuỗi chuẩn để loại bỏ hoàn toàn phần đuôi thập phân dư thừa, đồng thời giá nguyên trạng thái NaN đối với các ô khuyết thiếu.

Sang Bước 2, nhóm nghiên cứu tiến hành phân tách các nghiệp vụ hủy trả và điều chỉnh công nợ ra khỏi luồng giao dịch bán hàng. Bằng cách kiểm tra ký tự đầu tiên của chuỗi mã hóa đơn Invoice, toàn bộ các bản ghi bắt đầu bằng chữ cái C được tách riêng sang bảng dữ liệu hủy đơn (df_cancel), bao gồm 19.104 dòng bản ghi thuộc 8.292 hóa đơn hủy duy nhất (giảm từ 19.494 dòng trước khi khử trùng lặp). Đồng thời, 6 dòng bản ghi thuộc các hóa đơn điều chỉnh nợ xấu bắt đầu bằng chữ cái A cũng được loại bỏ hoàn toàn khỏi tập dữ liệu chính. Việc tách riêng bảng df_cancel thay vì xóa bỏ vĩnh viễn cho phép nhóm nghiên cứu tiếp tục khai thác thông tin này ở Giai đoạn 2.3 (đối chiếu các đơn hàng khống lồ bị hủy ngược) và Giai đoạn 3.5 (đo lường tỷ lệ hủy đơn theo thị trường).

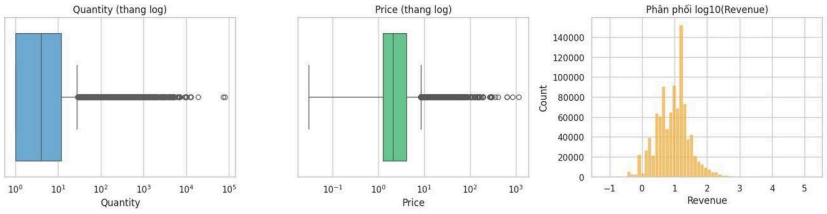
Tại Bước 3, hệ thống thực hiện lọc và loại bỏ các bản ghi có mã StockCode không đại diện cho hàng hóa thương mại thông thường. Sử dụng biểu thức chính quy nhận diện các mã chỉ chứa chữ cái, dấu gạch dưới, khoảng trắng hoặc bắt đầu bằng

hai tiền tố đặc biệt là DCGS và GIFT, chương trình đã xác định và loại bỏ chính xác 53 mã phi sản phẩm, bao gồm: ADJUST, AMAZONFEE, BANK CHARGES, D, chuỗi 30 mã từ DCGS0003 đến DCGS0076 cùng DCGSLBOY, DCGSLGIRL, DCGSSBOY, DCGSSGIRL, DOT, GIFT, chuỗi 9 mã phiếu quà tặng từ GIFT_0001_10 đến GIFT_0001_90, M, PADS, POST và S. Bước lọc này giúp loại bỏ hoàn toàn các khoản phụ phí vận chuyển, phí ngân hàng và chiết khấu khỏi danh mục sản phẩm.

Tiếp nối ở Bước 4, chương trình áp dụng điều kiện lọc kép chỉ giá lại các dòng giao dịch có đơn giá bán lớn hơn 0 (Price > 0) và số lượng sản phẩm lớn hơn 0 (Quantity > 0). Bước xử lý này đã loại bỏ thêm 5.936 dòng bản ghi có giá bằng 0 hoặc số lượng âm còn sót lại sau khi đã tách hóa đơn C (chủ yếu là các bút toán xuất hủy hàng hỏng tại kho, điều chỉnh kiểm kê hoặc hàng tặng kèm không tính tiền). Cuối cùng, ở Bước 5, nhóm nghiên cứu thực hiện chuẩn hóa tên mô tả sản phẩm (Description) bằng cách xác định tên gọi xuất hiện phổ biến nhất (mode) cho từng mã StockCode rồi ánh xạ ngược trở lại cho toàn bộ các dòng mang mã StockCode đó. Đáng chú ý, do toàn bộ 4.382 dòng thiếu Description trong dữ liệu gốc đều có đơn giá bằng 0 nên trước khi bước vào Bước 5, số lượng dòng thiếu Description trong bảng dữ liệu đã giảm về đúng bằng 0; mặc dù vậy, phép ánh xạ theo giá trị phổ biến nhất vẫn phát huy tác dụng to lớn trong việc hợp nhất 1.232 mã sản phẩm có nhiều tên gọi khác nhau về một tên thương mại chuẩn xác duy nhất.

2.3. Phát hiện giá trị ngoại lệ theo quy tắc IQR và lập luận giá đơn bán buôn

Sau khi hoàn tất năm bước làm sạch cơ bản và thu được 1.003.496 dòng giao dịch bán hàng hợp lệ, nhóm nghiên cứu khởi tạo biến doanh thu dòng hàng (Revenue = Quantity * Price) và tiến hành khảo sát hình dáng phân phối cũng như kiểm tra các điểm giá trị ngoại lệ trên ba biến định lượng cốt lõi là số lượng, đơn giá (Price) và doanh thu dòng hàng tại Ô lệnh 31 và 32. Kết quả tính toán hệ số bất đối xứng và trực quan hóa trên Hình 2.3.a cho thấy cả ba biến số đều mang phân phối lệch phải cực kỳ mạnh: hệ số lệch của Quantity lên tới 453,2;
hệ số lệch của Price là 39,9; và hệ số lệch của Revenue đạt mức 661,8. Chính vì biên độ dao động trải rộng qua nhiều bậc độ lớn, biểu đồ hộp của Quantity và Price trên Hình 2.3.a phải biểu diễn trên trục logarit cơ số 10, đồng thời biểu đồ tần suất của log10 (Revenue) cho thấy khi chuyển sang thang đo logarit, phân phối doanh thu dòng hàng mới tiệm cận dạng hình chuông đối xứng xoay quanh mốc 10 mũ 1 (tức khoảng 10 đến 15 Bảng Anh trên mỗi dòng sản phẩm).



Hình 2.3.a. Biểu đồ hộp của Quantity, Price trên thang logarit và biểu đồ phân phối log10(Revenue)

Khi áp dụng quy tắc khoảng tứ phân vị cổ điển (xác định ngưỡng trên bằng Q3 + 1,5 * IQR và ngưỡng dưới bằng Q1 - 1,5 * IQR) trên 1.003.496 dòng giao dịch, kết quả thống kê tại Ô lệnh 32 cho thấy một bức tranh hết sức đáng chú ý. Đối với biến Quantity, ngưỡng trên IQR chỉ dừng ở mức 28,50 đơn vị, phát hiện 53.019 dòng vượt ngưỡng (chiếm 5,3 phần trăm số dòng nhưng đóng góp tới 36,6 phần trăm tổng doanh

thu toàn doanh nghiệp). Đối với biến Price, ngưỡng trên IQR là 8,45 Bảng Anh, phát hiện 75.303 dòng vượt ngưỡng (chiếm 7,5 phần trăm số dòng và đóng góp 12,7 phần trăm doanh thu). Đặc biệt, đối với biến Revenue, ngưỡng trên IQR chỉ ở mức38,06 Bảng Anh, khiến 82.399 dòng giao dịch bị đánh dấu là ngoại lệ (chiếm 8,2 phần trăm số dòng nhưng nắm giá tới 50,2 phần trăm tổng doanh thu).

Để làm rõ bản chất của những giao dịch có quy mô vượt trội này là lỗi nhập liệu hay đơn đặt hàng bán buôn thực tế, nhóm nghiên cứu đã trích xuất 10 dòng giao dịch có số lượng đặt mua lớn nhất và tiến hành đối chiếu chéo với bảng hóa đơn hủy df_cancel theo bộ ba khóa (Customer ID, StockCode, -Quantity) tại Ô lệnh 33. Kết quả tại Bảng 2.3.b chỉ ra rằng hai giao dịch đứng đầu bảng là đơn hàng mua 80.995 sản phẩm thủ công giấy (PAPER CRAFT, LITTLE BIRDIE) vào ngày 09/12/2011 của khách hàng 16446 và đơn hàng mua 74.215 lọ gốm bảo quản (MEDIUM CERAMIC TOP STORAGE JAR) vào ngày 18/01/2011 của khách hàng 12346 đều xuất hiện bút toán hủy ngược với số lượng khớp tuyệt đối trong bảng df_cancel (Bị hủy lại = True). Ngược lại, toàn bộ 8 dòng giao dịch đứng kế tiếp với số lượng từ 10.000 đến 19.152 sản phẩm (như cốc sứ họa tiết hoa, cốc giấy dâu tây, đĩa giấy và khăn giấy đóng gói của khách hàng 13902 và 17940 với mức đơn giá sỉ rất thấp chỉ từ 0,10 đến 0,25 Bảng Anh) hoàn toàn không bị hủy lại (Bị hủy lại = False), chứng tỏ đây là các hợp đồng mua bán B2B hoàn toàn hợp lệ. Từ những bằng chứng thực nghiệm trên, nhóm nghiên cứu đi đến quyết định phương pháp luận quan trọng tại Ô lệnh 34: giá nguyên toàn bộ 1.003.496 dòng giao dịch bán hàng dương sau bước lọc mà không thực hiện cắt bỏ hàng loạt theo ngưỡng IQR. Lý do cốt lõi là quy tắc IQR chỉ là công cụ phát hiện điểm khác thường chứ không phải bằng chứng chứng minh lỗi dữ liệu; việc xóa bỏ 8,2 phần trăm số dòng vượt ngưỡng IQR của biến Revenue đồng nghĩa với việc xóa sổ hơn một nửa (50,2 phần trăm) tổng doanh thu hợp lệ của doanh nghiệp và làm biến mất hoàn toàn phân khúc khách hàng tổ chức mua sỉ.

Mã đơn	Mã hàng và Tên sản phẩm (StockCode - Description)	Số lượng	Đơn giá (£)	Mã KH	Bị hủy lại?
581483	23843 - PAPER CRAFT, LITTLE BIRDIE (09/12/2011)	80.995	2,08	16446	True (Có)
541431	23166 - MEDIUM CERAMIC TOP STORAGE JAR (18/01/2011)	74.215	1,04	12346	True (Có)
497946	37410 - BLACK AND WHITE PAISLEY FLOWER MUG (15/02/2010)	19.152	0,10	13902	False (Không)
501534	21099 - SET/6 STRAWBERRY PAPER CUPS (17/03/2010)	12.960	0,10	13902	False (Không)
501534	21091 - SET/6 WOODLAND PAPER PLATES (17/03/2010)	12.960	0,10	13902	False (Không)

501534	21085 - SET/6 WOODLAND PAPER CUPS (17/03/2010)	12.744	0,10	13902	False (Không)
501534	21092 - SET/6 STRAWBERRY PAPER PLATES (17/03/2010)	12.480	0,10	13902	False (Không)
502269	21984 - PACK OF 12 PINK PAISLEY TISSUES (23/03/2010)	10.000	0,25	17940	False (Không)
502269	21982 - PACK OF 12 SUKI TISSUES (23/03/2010)	10.000	0,25	17940	False (Không)
502269	21980 - PACK OF 12 RED RETROSPOT TISSUES (23/03/2010)	10.000	0,25	17940	False (Không)

Bảng 2.3.b. Kiểm tra 10 dòng giao dịch có số lượng (Quantity) lớn nhất và trạng thái hủy ngược

2.4. Kiến tạo đặc trưng thời gian và tổng kết kết quả làm sạch

Để chuẩn bị sẵn sàng cho các phân tích đa chiều ở Giai đoạn 3, bước cuối cùng của Giai đoạn 2 tại Ô lệnh 37 là kiến tạo hệ thống biến đặc trưng mới (Feature Engineering) từ trường thời gian InvoiceDate và trường địa lý Country, bao gồm: biến kỳ tháng-năm (YearMonth), biến năm dương lịch (Year), biến tháng trong năm (Month), biến tên ngày trong tuần (Weekday), biến khung giờ đặt hàng trong ngày (Hour) và biến nhị phân phân biệt thị trường nội địa Anh với quốc tế (IsUK). Đồng thời, từ bảng dữ liệu sạch tổng thể (df), chương trình trích xuất thêm bảng con gồm các giao dịch có đầy đủ mã định danh khách hàng (df_cust) để phục vụ riêng cho các bài toán phân tích theo khách hàng.

Chỉ tiêu thống kê quy mô	Dữ liệu gốc (df_raw)	Sau làm sạch (df)	Tập có định danh (df_cust)	Tỷ lệ giá lại của df so với gốc (%)
Tổng số dòng bản ghi	1.067.371	1.003.496	776.840	94,02%
Số lượng hóa đơn duy nhất	53.628	39.536	36.613	73,72%
Số lượng khách hàng định danh	5.942	5.853	5.853	98,50%
Số lượng mã sản phẩm (StockCode)	5.305	4.712	4.624	88,82%
Tổng doanh thu dòng bán hàng (£)	Chưa lọc dòng âm/trùng	19.657.090 £	16.648.292 £	Đạt 19.657.089,95 £

Bảng 2.4. Tổng kết đối chiếu quy mô bộ dữ liệu trước làm sạch, sau làm sạch và tập có Customer ID

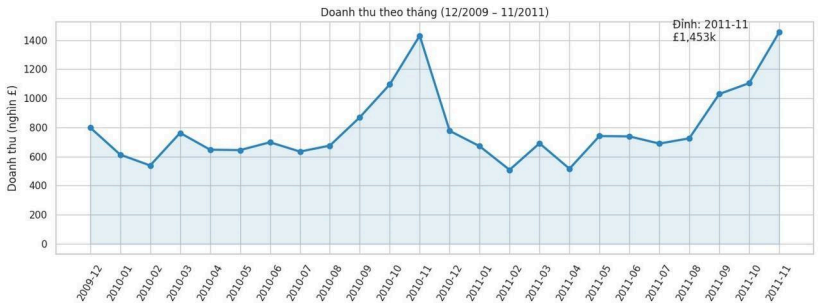
Nhìn vào Bảng 2.4, sau toàn bộ quy trình làm sạch 5 bước, tập dữ liệu sạch df giá lại 1.003.496 dòng bản ghi hợp lệ (tương đương 94,02 phần trăm số dòng ban đầu), đại diện cho 39.536 hóa đơn bán hàng thực chất của 5.853 khách hàng có định danh trên danh mục 4.712 mã sản phẩm chuẩn hóa, mang lại tổng doanh thu dòng bán hàng đạt 19.657.089,95 Bảng Anh (làm tròn là 19.657.090 Bảng Anh). Trong khi đó, tập con có mã định danh khách hàng df_cust bao gồm 776.840 dòng bản ghi (chiếm 77,41 phần trăm số dòng của tập dữ liệu sạch) và 36.613 hóa đơn bán hàng. Sự phân tách minh bạch giữa hai tập dữ liệu df và df_cust giúp báo cáo đảm bảo độ chính xác cao nhất cho từng góc nhìn phân tích ở Giai đoạn 3.

GIAI ĐOẠN 3: PHÂN TÍCH VÀ TRỰC QUAN HÓA DỮ LIỆU

Sau khi hoàn thiện công tác tiền xử lý và xác lập được tập dữ liệu sạch đạt chuẩn nghiệp vụ, Giai đoạn 3 đi sâu phân tích khám phá và trực quan hóa dữ liệu nhằm giải đáp toàn diện các câu hỏi nghiên cứu đã đề ra. Toàn bộ nội dung phân tích trong giai đoạn này bám sát sáu khía cạnh trọng tâm được triển khai trong tệp chương trình Google Colab của nhóm, bao gồm: biến động doanh thu theo thời gian và tính chất mùa vụ, cơ cấu thị trường theo quốc gia, so sánh phân phối giá trị đơn hàng giữa thị trường nội địa và quốc tế, phân bố nhịp điệu đặt hàng theo ngày trong tuần và khung giờ trong ngày, phân tích nhóm sản phẩm chủ lực gắn với tỷ lệ hủy đơn, và đánh giá mức độ tập trung doanh thu theo khách hàng thông qua đường cong Pareto.

3.1. Xu hướng doanh thu theo thời gian và tính chất mùa vụ

Để đánh giá chính xác quy luật vận động của doanh thu theo thời gian từ tháng 12/2009 đến cuối năm 2011, một thao tác xử lý kỹ thuật quan trọng đã được thực hiện tại Ô lệnh 40 trước khi vẽ biểu đồ chuỗi thời gian: loại bỏ kỳ tháng 12/2011 ra khỏi bảng tổng hợp theo tháng (monthly = monthly.iloc[:-1]). Nguyên nhân là bởi bộ dữ liệu ngừng thu thập vào lúc 12 giờ 50 phút ngày 09/12/2011, tức tháng 12/2011 chỉ mới diễn ra được 9 ngày đầu tháng; nếu giá lại tháng chưa hoàn chỉnh này trên biểu đồ đường, đường biểu diễn sẽ tạo cảm giác sụt giảm doanh thu đột ngột vào cuối kỳ hoàn toàn do yếu tố cắt mẫu kỹ thuật chứ không phải suy thoái kinh doanh thực tế. Chuỗi thời gian phân tích chuẩn xác do đó bao gồm 24 tháng đầy đủ liên tiếp, kéo dài từ tháng 12/2009 đến hết tháng 11/2011.



Hình 3.1.a. Biến động doanh thu theo tháng giai đoạn từ tháng 12/2009 đến tháng 11/2011

Quan sát số liệu chi tiết 12 tháng cuối kỳ tại Hình 3.1.a, có thể nhận diện rõ rệt quy luật chu kỳ mùa vụ lặp lại nhất quán trong cả hai năm kinh doanh của doanh nghiệp. Trong tám tháng đầu mỗi năm (từ tháng 1 đến tháng 8), doanh thu hàng tháng duy trì ở vùng nền tương đối ổn định, dao động trong khoảng từ hơn 500 nghìn Bảng Anh đến dưới 760 nghìn Bảng Anh mỗi tháng, trong đó điểm trũng thấp nhất thường rơi vào tháng 2 và tháng 4 (điển hình như tháng 02/2011 đạt 507.998,42 Bảng Anh với 1.093 đơn hàng và tháng 04/2011 đạt 515.754,78 Bảng Anh với 1.235 đơn hàng). Tuy nhiên, bước sang giai đoạn mùa thu - đông từ tháng 9 đến tháng 11 hằng năm, doanh thu bứt phá mạnh mẽ theo phương thẳng đứng: trong năm 2011, doanh thu tăng vọt từ mức 724.596,76 Bảng Anh của tháng 08/2011 lên 1.029.213,80 Bảng Anh vào tháng 09/2011, tiếp tục leo lên 1.104.010,96 Bảng Anh vào tháng 10/2011 và xác lập đỉnh cao lịch sử toàn chuỗi vào tháng 11/2011 ở mức 1.453.262,69 Bảng Anh (tương ứng 2.751 đơn hàng từ 1.660 khách hàng định danh với giá trị đơn hàng trung bình đạt 528,27 Bảng Anh).

Kỳ tháng (YearMonth)	Doanh thu (Revenue - £)	Số hóa đơn (Orders)	Số khách hàng (Customers)	Giá trị đơn TB (AOV - £)
2010-12	776.172,23	1.551	884	500,43
2011-01	670.561,99	1.081	739	620,32
2011-02	507.998,42	1.093	757	464,77
2011-03	690.458,49	1.440	973	479,49
2011-04	515.754,78	1.235	853	417,62
2011-05	740.350,35	1.668	1.054	443,86
2011-06	738.108,98	1.525	990	484,01
2011-07	688.694,79	1.452	946	474,31
2011-08	724.596,76	1.340	933	540,74
2011-09	1.029.213,80	1.819	1.259	565,81
2011-10	1.104.010,96	2.005	1.361	550,63
2011-11	1.453.262,69	2.751	1.660	528,27

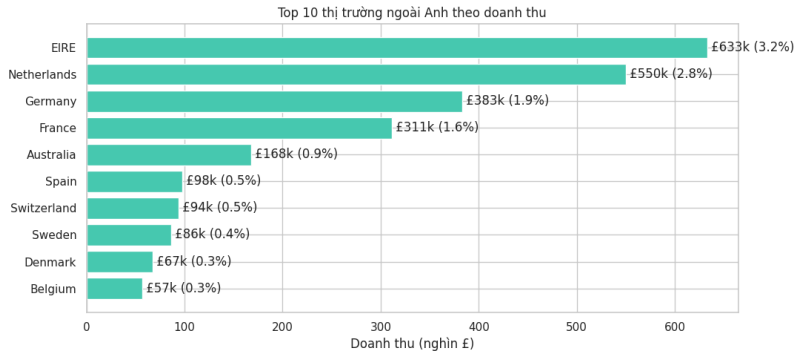
Bảng 3.1.b. Diễn biến doanh thu, số đơn hàng, số khách hàng và AOV trong 12 tháng cuối kỳ

Để lượng hóa rõ hơn dấu hiệu mùa vụ và tốc độ tăng trưởng giữa hai niên độ, nhóm nghiên cứu tiến hành bóc tách tỷ trọng doanh thu theo từng quý của năm dương lịch 2010 (năm dương lịch duy nhất có đủ trọn vẹn 12 tháng từ tháng 1 đến tháng 12 trong bộ dữ liệu) tại Ô lệnh 41, đồng thời so sánh mức doanh thu trung bình hàng tháng của cụm ba tháng cao điểm (tháng 9, tháng 10, tháng 11) với các tháng còn lại. Số liệu thực nghiệm cho thấy trong năm 2010, tỷ trọng doanh thu tăng dần đều từ Quý 1 (chiếm 20,40 phần trăm), sang Quý 2 (chiếm 21,20 phần trăm), lên Quý 3 (chiếm 23,20 phần trăm) và tập trung đột biến vào Quý 4 với tỷ trọng lên tới 35,20 phần trăm tổng doanh thu cả năm. Xét trên toàn chuỗi 24 tháng, doanh thu trung bình mỗi tháng trong giai đoạn cao điểm từ tháng 9 đến tháng 11 đạt 1.163.717,13 Bảng Anh (tương đương 1.163,72 nghìn Bảng Anh), cao gấp 1,74 lần so với mức trung bình 670.005,53 Bảng Anh (tương đương 670,01 nghìn Bảng Anh) của các tháng còn lại. Bản chất kinh tế của hiện tượng này xuất phát từ việc các đại lý bán lẻ và đối tác doanh nghiệp tập trung nhập sỉ hàng trang trí, quà tặng với số lượng lớn từ tháng 9 đến tháng 11 để chuẩn bị hàng hóa bày bán cho mùa lễ hội Giáng sinh và Năm mới tại châu Âu. Ngoài ra, khi so sánh hai chu kỳ 12 tháng tương ứng là kỳ thứ nhất (12/2009 - 11/2010) đạt 9.403.218 Bảng Anh và kỳ thứ hai (12/2010 - 11/2011) đạt 9.639.184 Bảng Anh, quy mô doanh thu của doanh nghiệp ghi nhận mức tăng trưởng dương ổn định là 2,5 phần trăm.

3.2. Cơ cấu thị trường tiêu thụ theo quốc gia

Khía cạnh phân tích thứ hai tập trung đánh giá sự phân bổ doanh thu và tệp khách hàng theo không gian địa lý. Kết quả tổng hợp theo trường Country tại Ô lệnh 44 và 59 khẳng định vị thế áp đảo tuyệt đối của thị trường nội địa Vương quốc Anh (United Kingdom): tính trên toàn bộ tập dữ liệu sạch, riêng thị trường Vương quốc Anh đã đóng góp tới 85,48 phần trăm (làm tròn 85,5 phần trăm) tổng doanh thu bán

hàng (tương đương khoảng 16,80 triệu Bảng Anh trên tổng số 19,66 triệu Bảng Anh) và chiếm tới 91,1 phần trăm tổng số khách hàng có mã định danh của doanh nghiệp. Phần doanh thu còn lại khoảng 14,52 phần trăm (tương đương 2,85 triệu Bảng Anh) được tạo ra từ các hoạt động xuất khẩu xuyên biên giới tới các quốc gia ngoài nước Anh.

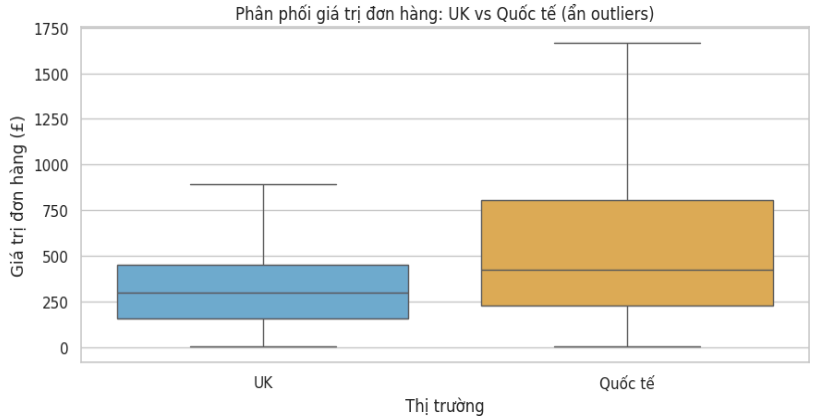


Hình 3.2. Mười thị trường quốc tế lớn nhất ngoài Vương quốc Anh xét theo quy mô doanh thu

Do quy mô của thị trường nội địa Vương quốc Anh quá lớn sẽ làm che khuất sự khác biệt giữa các quốc gia xuất khẩu nếu vẽ trên cùng một thang đo, Hình 3.2 đã tách riêng 10 thị trường quốc tế có doanh thu cao nhất ngoài nước Anh để khảo sát chi tiết. Dẫn đầu khối thị trường quốc tế là Cộng hòa Ireland (được ký hiệu là EIRE trong hệ thống) với doanh thu đạt 633 nghìn Bảng Anh, chiếm 3,2 phần trăm tổng doanh thu toàn doanh nghiệp. Đứng ở vị trí thứ hai là Hà Lan (Netherlands) với doanh thu 550 nghìn Bảng Anh (chiếm 2,8 phần trăm), theo sát là hai nền kinh tế lớn nhất Tây Âu gồm Cộng hòa Liên bang Đức (Germany) đạt 383 nghìn Bảng Anh (chiếm 1,9 phần trăm) và Cộng hòa Pháp (France) đạt 311 nghìn Bảng Anh (chiếm 1,6 phần trăm). Đáng chú ý, dù cách xa về khoảng cách địa lý nhưng Australia vẫn vươn lên vị trí thứ năm với 168 nghìn Bảng Anh (chiếm 0,9 phần trăm), xếp trên một loạt quốc gia châu Âu khác là Tây Ban Nha (98 nghìn Bảng Anh - 0,5 phần trăm), Thụy Sĩ (94 nghìn Bảng Anh - 0,5 phần trăm), Thụy Điển (86 nghìn Bảng Anh - 0,4 phần trăm), Đan Mạch (67 nghìn Bảng Anh - 0,3 phần trăm) và Bỉ (57 nghìn Bảng Anh - 0,3 phần trăm). Như vậy, chỉ riêng 4 thị trường láng giềng Tây Âu đứng đầu (Ireland, Hà Lan, Đức, Pháp) đã đóng góp tới 1.877 nghìn Bảng Anh, tương đương 9,5 phần trăm tổng doanh thu toàn công ty và chiếm gần hai phần ba tổng kim ngạch xuất khẩu ngoài nước Anh.

3.3. So sánh phân phối giá trị đơn hàng giữa thị trường Anh và quốc tế

Mặc dù thị trường quốc tế ngoài Vương quốc Anh chỉ chiếm 14,52% tổng doanh thu và 8,9% số lượng khách hàng định danh, việc đi sâu phân tích quy mô giá trị trên từng hóa đơn đặt hàng (Average Order Value - AOV) trên tập dữ liệu có định danh khách hàng (df_cust) tại Ô lệnh 46 lại mở ra một góc nhìn chiến lược hoàn toàn khác biệt. Nhóm nghiên cứu tiến hành gom nhóm doanh thu theo từng mã hóa đơn (Invoice) kết hợp với nhãn khu vực thị trường (UK so với Quốc tế), sau đó vẽ biểu đồ hộp so sánh phân phối (ẩn các điểm ngoại lệ cực đoan để quan sát rõ hộp tứ phân vị) và tính toán song song hai đại lượng trung tâm là giá trị trung bình cộng (mean) và giá trị trung vị (median).



Hình 3.3.a. Biểu đồ hộp so sánh phân phối giá trị đơn hàng giữa thị trường UK và Quốc tế (ẩn điểm ngoại lệ)

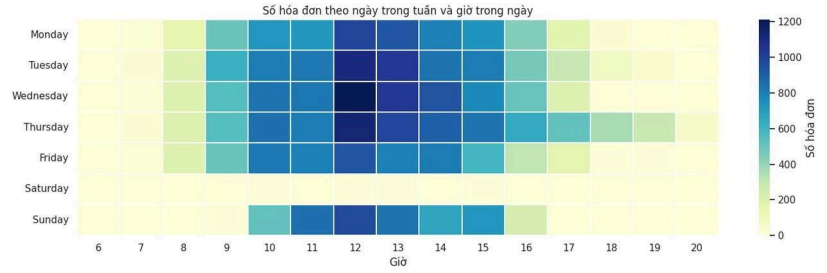
Kết quả thực nghiệm trên Hình 3.3.a và Bảng 3.3.b cho thấy một sự chênh lệch rõ rệt về quy mô đơn hàng giữa hai khu vực thị trường. Trong tổng số 36.613 hóa đơn có định danh khách hàng, khu vực nội địa Vương quốc Anh đóng góp 33.374 hóa đơn với giá trị đơn hàng trung bình đạt 428,26 Bảng Anh và giá trị trung vị đạt 299,47 Bảng Anh. Ngược lại, khu vực thị trường quốc tế tuy chỉ có 3.239 hóa đơn nhưng giá trị đơn hàng trung bình vọt lên mức 861,22 Bảng Anh (cao gấp hơn 2,01 lần mức trung bình của thị trường nội địa Anh) và giá trị trung vị đạt 423,90 Bảng Anh (cao gấp 1,42 lần mức trung vị của thị trường Anh). Quan sát trực quan trên Hình 3.3.a cũng khẳng định toàn bộ hộp phân vị của nhóm đơn hàng quốc tế (màu cam) nằm dịch chuyển hẳn lên phía trên và có độ trải rộng lớn hơn nhiều so với hộp phân vị của thị trường Anh (màu xanh dương): cạnh trên của hộp (phân vị thứ 75) ở thị trường quốc tế chạm mốc khoảng 800 Bảng Anh và râu trên vượt mức 1.650 Bảng Anh, trong khi ở thị trường Anh phân vị thứ 75 chỉ quanh mức 450 Bảng Anh và râu trên dừng ở khoảng 890 Bảng Anh. Sự khác biệt này hoàn toàn hợp lý dưới góc độ kinh tế vận tải: do chi phí cước vận chuyển quốc tế, thủ tục hải quan và thời gian giao hàng xuyên biên giới lớn hơn nhiều so với giao hàng nội địa, các khách hàng nước ngoài hầu hết là các nhà phân phối hoặc cửa hàng bán lẻ đặt mua gom theo lô lớn để tối ưu hóa chi phí vận chuyển trên mỗi đơn vị hàng hóa.

Khu vực thị trường	Số đơn có ID (count)	Giá trị đơn TB (mean - £)	Giá trị đơn trung vị (median - £)	Tỷ lệ hóa đơn hủy (%)
Thị trường Quốc tế (Ngoài UK)	3.239	861,22 £	423,90 £	22,64%
Thị trường Nội địa (UK)	33.374	428,26 £	299,47 £	16,81%
Chênh lệch / Tỷ lệ so sánh	Tổng: 36.613 đơn	Gấp 2,01 lần UK	Gấp 1,42 lần UK	Cao hơn 5,83 điểm %

Bảng 3.3.b So sánh quy mô giá trị đơn hàng (£) và tỷ lệ hóa đơn hủy giữa thị trường UK và Quốc tế

3.4. Phân bố thời điểm đặt hàng theo ngày trong tuần và giờ trong ngày

Để phục vụ công tác điều phối nhân sự vận hành kho bãi, đóng gói đơn hàng và bố trí ca trực hệ thống công nghệ thông tin, nhóm nghiên cứu tiến hành phân tích mật độ phát sinh hóa đơn theo ma trận hai chiều giữa các ngày trong tuần (từ thứ Hai đến Chủ nhật) và các khung giờ trong ngày (từ 06 giờ sáng đến 20 giờ tối) tại Ô lệnh 49. Lưu ý quan trọng về mặt kỹ thuật xử lý là trước khi lập bảng chéo (pivot_table), dữ liệu phải được lọc duy nhất theo mã hóa đơn (df.drop_duplicates(Invoice)) để mỗi hóa đơn chỉ được đếm đúng một lần tại thời điểm phát sinh, tránh việc một hóa đơn mua hàng trăm mặt hàng làm phình ảo mật độ giao dịch của một khung giờ cụ thể.



Hình 3.4. Biểu đồ nhiệt thể hiện mật độ số lượng hóa đơn theo ngày trong tuần và khung giờ trong ngày

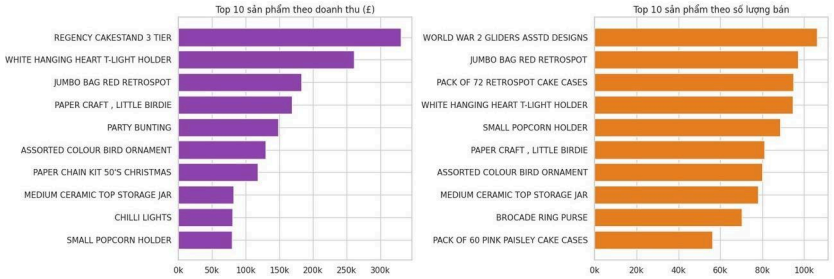
Quan sát biểu đồ nhiệt trên Hình 3.4 kết hợp với kết quả tính tỷ trọng hóa đơn theo ngày trong tuần tại Ô lệnh 49, có thể rút ra những quy luật vận hành hết sức rõ nét theo cả chiều ngày lẫn chiều giờ. Xét theo các ngày trong tuần, lưu lượng hóa đơn tập trung chủ yếu vào năm ngày làm việc hành chính từ thứ Hai đến thứ Sáu (chiếm tổng cộng 87,80 phần trăm tổng số hóa đơn cả tuần), nhưng mức độ phân bổ giữa các ngày làm việc không hề đồng đều nhau: ngày thứ Năm (Thursday) là ngày bận rộn nhất trong tuần khi chiếm tới 20,70 phần trăm tổng số hóa đơn, theo sau là ngày thứ Ba (Tuesday - chiếm 18,10 phần trăm) và ngày thứ Tư (Wednesday - chiếm 18,00 phần trăm); trong khi đó hai ngày đầu tuần và cuối tuần làm việc có tỷ trọng thấp hơn đáng kể là thứ Hai (Monday - chiếm 15,80 phần trăm) và thứ Sáu (Friday - chiếm 15,20 phần trăm). Đáng chú ý nhất vào dịp cuối tuần, ngày thứ Bảy (Saturday) gần như trắng toàn bộ trên biểu đồ nhiệt với tỷ trọng chỉ vẻn vẹn 0,10 phần trăm tổng số hóa đơn, trong khi ngày Chủ nhật (Sunday) hoạt động trở lại sôi động và đóng góp 12,20 phần trăm tổng số hóa đơn. Hiện tượng ngày thứ Bảy hầu như không có hóa đơn phản ánh quy định đóng cửa nghỉ giao dịch hoặc ngừng xử lý xuất hóa đơn vào thứ Bảy của doanh nghiệp bán buôn này, chứ không phải do người tiêu dùng tự nhiên ngừng mua sắm vào thứ Bảy.

Xét theo chiều khung giờ trong ngày trên trục hoành của Hình 3.4, các ô màu xanh đậm nhất tập trung dày đặc trong khoảng từ 10 giờ sáng đến 15 giờ chiều, đạt đỉnh điểm cao nhất vào khung giờ 12 giờ trưa đến 13 giờ chiều ở tất cả các ngày từ thứ Hai đến thứ Sáu cũng như Chủ nhật (với mật độ vượt mức 1.000 đến 1.200 hóa đơn mỗi ô vào khung 12 giờ trưa các ngày thứ Ba, thứ Tư và thứ Năm). Trước 08 giờ sáng và sau 17 giờ chiều, số lượng hóa đơn giảm xuống rất thấp; ngoại lệ duy nhất là chiều tối ngày thứ Năm khi hoạt động đặt hàng kéo dài đến tận khung 17 giờ - 19 giờ tối với mật độ vẫn đạt từ 200 đến 500 hóa đơn. Quy luật tập trung đơn hàng vào khung giờ hành chính giữa ngày (10 giờ - 15 giờ) một lần nữa củng cố kết luận rằng

tệp khách hàng chủ lực của doanh nghiệp là các nhân viên thu mua và chủ cửa hàng kinh doanh thực hiện đặt hàng trong giờ làm việc ban ngày.

3.5. Phân tích nhóm sản phẩm chủ lực và tỷ lệ hủy đơn hàng

Trên phương diện quản trị danh mục hàng hóa (Merchandising), nhóm nghiên cứu tiến hành tổng hợp doanh thu, tổng số lượng tiêu thụ và số lượng hóa đơn xuất hiện cho toàn bộ 4.675 tên sản phẩm chuẩn hóa (Description) trong tập dữ liệu sạch tại Ô lệnh 52. Phép kiểm tra độ tập trung doanh thu theo sản phẩm cho thấy quy luật phân bổ Pareto thể hiện rất rõ trên danh mục hàng hóa: chỉ riêng 20 phần trăm số lượng sản phẩm dẫn đầu (tương ứng khoảng 935 mặt hàng) đã tạo ra tới 77,9 phần trăm tổng doanh thu của toàn doanh nghiệp, trong khi 80 phần trăm số lượng mặt hàng còn lại chỉ đóng góp 22,1 phần trăm doanh thu.



Hình 3.5. Mười sản phẩm dẫn đầu xét theo tổng doanh thu (£) và xét theo tổng số lượng bán ra

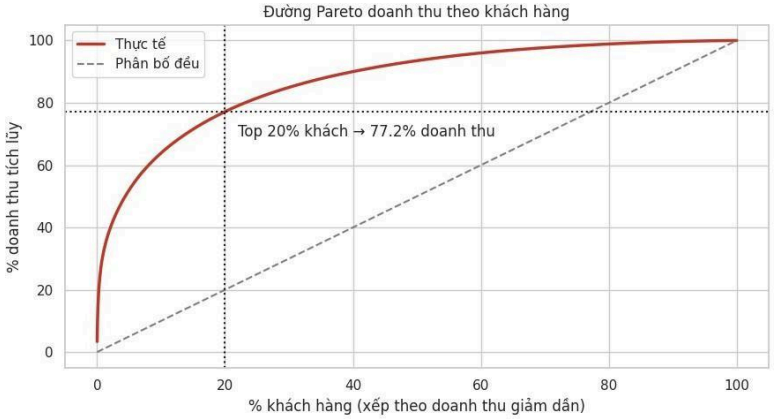
Quan sát hai biểu đồ thanh ngang đặt song song trên Hình 3.5, có thể thấy sự khác biệt thú vị giữa danh sách 10 mặt hàng dẫn đầu về doanh thu (biểu đồ bên trái màu tím) và 10 mặt hàng dẫn đầu về sản lượng đơn vị bán ra (biểu đồ bên phải màu cam). Xét về quy mô doanh thu bằng đồng Bảng Anh, vị trí quán quân thuộc về khay đựng bánh 3 tầng phong cách cổ điển (REGENCY CAKESTAND 3 TIER) với doanh thu vượt mức 330 nghìn Bảng Anh, bỏ xa vị trí thứ hai là giá treo nến hình trái tim màu trắng (WHITE HANGING HEART T-LIGHT HOLDER) đạt khoảng 260 nghìn Bảng Anh và vị trí thứ ba là túi cỡ lớn họa tiết chấm bi đỏ (JUMBO BAG RED RETROSPOT) đạt khoảng 180 nghìn Bảng Anh; các vị trí tiếp theo trong Top 10 doanh thu lần lượt là PAPER CRAFT LITTLE BIRDIE, dây cờ trang trí tiệc PARTY BUNTING, chim trang trí nhiều màu ASSORTED COLOUR BIRD ORNAMENT, bộ dây xích giấy Giáng sinh PAPER CHAIN KIT 50S CHRISTMAS, lọ gốm bảo quản MEDIUM CERAMIC TOP STORAGE JAR, đèn trang trí hình ớt CHILLI LIGHTS và hộp đựng bắp rang bơ SMALL POPCORN HOLDER. Trong khi đó, xét về tổng số lượng đơn vị bán ra, dẫn đầu lại là các mặt hàng đồ chơi giấy và bao bì giá rẻ bán theo lốc số lượng lớn: đứng đầu là tàu lượn mô hình Thế chiến 2 (WORLD WAR 2 GLIDERS ASSTD DESIGNS) với hơn 105 nghìn đơn vị, thứ hai là túi JUMBO BAG RED RETROSPOT (hơn 96 nghìn đơn vị), và thứ ba là bộ 72 khuôn giấy nướng bánh chấm bi (PACK OF 72 RETROSPOT CAKE CASES) với gần 95 nghìn đơn vị. Đáng chú ý, có 6 mặt hàng xuất hiện đồng thời ở cả hai bảng xếp hạng; đây chính là những mặt hàng chiến lược vừa có tốc độ luân chuyển kho cực nhanh vừa mang lại dòng tiền lớn cho doanh nghiệp.

Song hành với việc nhận diện các mặt hàng bán chạy, nhóm nghiên cứu đã khai thác bảng hóa đơn hủy df_cancel (đã tách riêng ở Giai đoạn 2) tại Ô lệnh 53 để đo lường quy mô tổn thất doanh thu và tỷ lệ hủy đơn theo khu vực thị trường (đã tổng hợp tại Bảng 3.3.b). Kết quả tính toán chỉ ra rằng tổng giá trị hàng hóa ghi nhận trên các hóa đơn hủy trả lên tới 1.462.051 Bảng Anh, tương đương 7,4% tổng doanh thu

dòng bán hàng dương của toàn doanh nghiệp. Đặc biệt, khi tính tỷ lệ số lượng hóa đơn hủy trên tổng số hóa đơn phát sinh (bao gồm cả đơn thành công và đơn hủy), thị trường quốc tế ngoài nước Anh ghi nhận tỷ lệ hóa đơn bị hủy lên tới 22,64 phần trăm, cao hơn đáng kể so với mức 16,81 phần trăm tại thị trường nội địa Vương quốc Anh. Như đã phân tích tại Giai đoạn 2.3, hai dòng giao dịch có số lượng lớn nhất toàn bộ dữ liệu (80.995 và 74.215 đơn vị) tuy nằm trong bảng bán hàng dương nhưng ngay sau đó đã bị hủy toàn bộ trong bảng df_cancel, khiến hai mặt hàng PAPER CRAFT LITTLE BIRDIE và MEDIUM CERAMIC TOP STORAGE JAR lọt vào Top 10 doanh thu bán hàng dương dù thực tế đã bị hoàn trả. Phát hiện này cho thấy tầm quan trọng sống còn của việc kiểm soát rủi ro hủy đơn và đối chiếu đơn hàng lớn.

3.6. Mức độ tập trung doanh thu theo khách hàng và đường cong Pareto

Nội dung phân tích cuối cùng trong Giai đoạn 3 đi sâu kiểm chứng quy luật tập trung doanh thu theo khách hàng trên tập dữ liệu có định danh (df_cust gồm 5.853 khách hàng) tại Ô lệnh 56. Bằng cách tính tổng doanh thu đóng góp của từng mã Customer ID, sắp xếp theo thứ tự giảm dần từ khách hàng lớn nhất đến khách hàng nhỏ nhất và vẽ đường cong tỷ trọng doanh thu tích lũy theo tỷ lệ phần trăm số lượng khách hàng, nhóm nghiên cứu thu được đường cong Pareto (còn gọi là đường cong Lorenz đảo ngược) thể hiện trên Hình 3.6.



Hình 3.6. Đường cong tích lũy Pareto phản ánh mức độ tập trung doanh thu theo khách hàng

Quan sát Hình 3.6, đường cong thực tế màu đỏ uốn cong vọt lên rất cao ngay từ những phần trăm khách hàng đầu tiên và tách biệt hoàn toàn khỏi đường chéo phân bố đều màu xám nét đứt. Kết quả tính toán chính xác tại Ô lệnh 56 và 59 cho thấy nhóm 20% khách hàng lớn nhất (tương ứng 1.170 khách hàng đầu bảng) đã tạo ra tới 77,16% (hiển thị trên biểu đồ là 77,2%) tổng doanh thu có định danh - một con số bám sát quy luật Pareto 80/20 cổ điển trong kinh tế học. Nếu xét mốc tích lũy đúng 80 phần trăm tổng doanh thu có định danh, doanh nghiệp chỉ cần đúng 1.353 khách hàng hàng đầu, tương ứng 23,% tổng số khách hàng định danh. Đáng kinh ngạc hơn, chỉ riêng 10 khách hàng lớn nhất toàn công ty (chiếm chưa đầy 0,17% tổng số khách hàng) đã đóng góp tới 16,2% tổng doanh thu có định danh. Cấu trúc tập trung cực cao này chứng minh mô hình kinh doanh thực chất của doanh nghiệp dựa rất nặng vào một nhóm nhỏ các đại lý và nhà phân phối mua buôn quy mô lớn: đây vừa là lợi thế giúp tiết giảm chi phí phục vụ trên một đồng doanh thu, nhưng đồng thời cũng đặt doanh nghiệp trước rủi ro tập trung khách hàng rất lớn nếu một vài đối tác nằm trong nhóm 10 khách hàng đầu bảng ngưng hợp tác hoặc chuyển sang nhà cung cấp đối thủ.

GIAI ĐOẠN 4: ĐÁNH GIÁ TÁC ĐỘNG, KHUYẾN NGHỊ VÀ GIỚI HẠN NGHIÊN CỨU

4.1. Tổng hợp câu hỏi nghiên cứu và hệ thống bằng chứng thực nghiệm

Giai đoạn 4 đóng vai trò kết nối toàn bộ các kết quả tính toán định lượng và biểu đồ trực quan từ ba giai đoạn trước thành một hệ thống luận cứ phục vụ quản trị doanh nghiệp. Trọng tâm của giai đoạn này là trả lời câu hỏi cốt lõi: những phát hiện từ dữ liệu giúp nhà quản trị đưa ra quyết định thực tiễn gì, mỗi phát hiện gắn liền với bằng chứng số liệu nào, và ranh giới diễn giải hợp lý nằm ở đâu để tránh việc suy diễn quá mức từ dữ liệu quan sát. Bảng 4.1 tổng hợp đối chiếu trực tiếp bốn câu hỏi nghiên cứu trọng tâm với toàn bộ các chỉ số thực nghiệm trích xuất tự động từ Ô lệnh 59 và nguyên tắc kết luận chuẩn mực tại Mục 4.1 của tệp Google Colab.

Câu hỏi nghiên cứu trọng tâm	Bằng chứng định lượng trích từ kết quả Colab (Ô lệnh 59)	Kết luận thực chất và giới hạn diễn giải chuẩn mực
1. Biến động doanh thu theo thời gian và mùa vụ	Tổng doanh thu dòng bán hàng đạt 19.657.089,95 £ (1.003.496 dòng, 39.536 hóa đơn). Quý 4/2010 chiếm 35,2% cả năm; TB tháng 9-11 đạt 1.163.717,13 £ so với 670.005,53 £ các tháng khác; đỉnh tháng 11/2011 đạt 1.453.262,69 £.	Dữ liệu quan sát cho thấy dấu hiệu mùa vụ cuối năm rất rõ nét (tăng gấp 1,74 lần); tuy nhiên chuỗi chỉ mới gồm 2 năm nên dùng làm tín hiệu lập kế hoạch kho vận, không khẳng định quy luật bất biến.
2. Mức độ tập trung doanh thu theo khách hàng	Trên 5.853 khách hàng có định danh (df_cust = 776.840 dòng), Top 20% khách hàng tạo ra 77,16% doanh thu; 1.353 khách (23,1%) tạo ra 80% doanh thu; Top 10 khách chiếm 16,2%.	Doanh thu tập trung rất cao vào nhóm khách sỉ cốt lõi; lưu ý kết quả chỉ áp dụng cho tập khách có Customer ID, không khái quát trực tiếp sang 22,77% dòng vãng lai.
3. Cơ cấu thị trường và khác biệt quy mô đơn hàng UK và Quốc tế	UK chiếm 85,48% doanh thu và 91,1% khách hàng; Top nước ngoài dẫn đầu bởi EIRE (633k £), Hà Lan (550k £). Đơn quốc tế (3.239 đơn) có trung bình 861,22 £, trung vị 423,90 £ so với UK (33.374 đơn, TB 428,26 £, trung vị 299,47 £).	Thị trường nội địa là trụ cột doanh thu, nhưng đơn hàng quốc tế có quy mô trung bình gấp 2,01 lần và trung vị gấp 1,42 lần do đặc thù nhập sỉ theo lô lớn để tối ưu cước vận tải.
4. Nhịp điệu thời điểm đặt hàng, sản phẩm chủ lực và tỷ lệ hủy đơn	Heatmap Hình 3.4 (Thứ Năm chiếm 20,7%, Thứ Bảy 0,1%, cao điểm 10h–15h); Top 20% sản phẩm tạo 77,9% doanh thu trên 4.675 mặt hàng; giá trị hủy 1.462.051 £ (7,4%), tỷ lệ hủy Quốc tế 22,64% vs UK 16,81%.	Đơn hàng tập trung vào khung giờ hành chính giữa tuần; danh mục sản phẩm tuân theo quy luật Pareto; tỷ lệ hóa đơn hủy ở thị trường quốc tế cao hơn nội địa 5,83 điểm phần trăm.

Bảng 4.1. Tổng hợp đối chiếu câu hỏi nghiên cứu, bằng chứng thực nghiệm từ Colab và kết luận

4.2. Các phát hiện kinh doanh trọng yếu và hàm ý quản trị

Từ hệ thống bằng chứng thực nghiệm đã tổng hợp, nghiên cứu đúc kết sáu phát hiện kinh doanh trọng yếu tương ứng với sáu trụ cột quản trị của doanh nghiệp. Phát hiện thứ nhất liên quan đến xu hướng doanh thu theo thời gian: biểu đồ đường doanh thu tháng và cơ cấu doanh thu theo quý cho thấy nhu cầu mua sắm tăng vọt trong giai đoạn từ tháng 9 đến tháng 11 hằng năm, với mức doanh thu bình quân tháng cao hơn 73,7 phần trăm so với các tháng bình thường và Quý 4 chiếm hơn một phần ba doanh thu cả năm. Đây là tín hiệu thực nghiệm rõ ràng để bộ phận chuỗi cung ứng chủ động nâng mức dự trữ tồn kho an toàn và tuyển dụng nhân sự thời vụ ngay từ cuối tháng 8. Tuy nhiên, giới hạn cần lưu ý là hai đầu chuỗi thời gian năm 2009 và năm 2011 không đủ 12 tháng dương lịch (tháng 12/2011 chỉ có 9 ngày nên đã được loại khỏi chuỗi tháng), do đó cần tiếp tục theo dõi thêm các niên độ tiếp theo.

Phát hiện thứ hai về cơ cấu thị trường địa lý chỉ ra rằng Vương quốc Anh giá vai trò thị trường nền tảng khi mang lại 85,48 phần trăm doanh thu, trong khi 10 quốc gia dẫn đầu ngoài nước Anh (đặc biệt là Ireland, Hà Lan, Đức, Pháp và Australia) tạo ra những đơn hàng có quy mô trung bình (861,22 Bảng Anh) cao gấp đôi đơn hàng nội địa (428,26 Bảng Anh). Tuy nhiên, dưới góc độ quản trị tài chính, doanh thu gộp cao tại thị trường quốc tế không tự động đồng nghĩa với lợi nhuận ròng cao, bởi bộ dữ liệu hiện tại chưa bao gồm chi phí vận chuyển xuyên biên giới, phí bảo hiểm hàng hóa, thuế nhập khẩu và chi phí xử lý rủi ro hoàn trả (vốn lên tới 22,64 phần trăm số hóa đơn ở thị trường quốc tế). Do đó, nhà quản trị nên xem các thị trường Tây Âu như cơ hội mở rộng có chọn lọc sau khi đã khấu trừ chi phí logistics.

Phát hiện thứ ba về cơ cấu danh mục sản phẩm cho thấy sự phân hóa mạnh mẽ khi 20 phần trăm mặt hàng hàng đầu đóng góp tới 77,9 phần trăm doanh thu, đồng thời có sự khác biệt giữa nhóm sản phẩm dẫn đầu về doanh thu bằng tiền (như khay bánh 3 tầng REGENCY CAKESTAND 3 TIER) và nhóm dẫn đầu về số lượng đơn vị xuất kho (như đồ chơi giấy WORLD WAR 2 GLIDERS ASSTD DESIGNS). Hai chỉ tiêu này giải quyết hai bài toán quản trị khác nhau: mặt hàng có doanh thu lớn quyết định dòng tiền và cần được ưu tiên bảo đảm nguồn cung không đứt gãy, trong khi mặt hàng có sản lượng đơn vị lớn quyết định diện tích lưu kho, vật tư đóng gói và định mức lao động bốc xếp tại kho bãi. Hơn nữa, trước khi quyết định mở rộng nhập hàng cho bất kỳ mã sản phẩm nào, bộ phận mua hàng cần đối chiếu thêm biên lợi nhuận gộp trên từng đơn vị sản phẩm.

Phát hiện thứ tư về sự tập trung doanh thu theo khách hàng thông qua đường cong Pareto khẳng định 20% khách hàng định danh hàng đầu tạo ra 77,16% doanh thu và chỉ riêng 10 khách hàng lớn nhất đã nắm giá 16,2% doanh thu có định danh. Cấu trúc này đòi hỏi doanh nghiệp phải triển khai song song hai chiến lược: một mặt thiết lập cơ chế chăm sóc chuyên biệt (Key Account Management) để giá chân nhóm 1.353 khách hàng cốt lõi tạo ra 80% doanh thu, mặt khác phải chủ động phát triển thêm tệp khách hàng sỉ tầm trung nhằm phân tán rủi ro phụ thuộc. Giới hạn bắt buộc phải ghi nhận là kết quả này chỉ tính trên 776.840 dòng có mã Customer ID và không bao gồm 22,77% giao dịch vãng lai.

Phát hiện thứ năm và thứ sáu liên quan đến nhịp điệu thời gian đặt hàng và thực trạng hủy trả đơn hàng. Ma trận nhiệt ngày và giờ chỉ ra rằng áp lực xử lý đơn hàng dồn nén mạnh nhất vào khung giờ từ 10 giờ sáng đến 15 giờ chiều các ngày làm việc trong tuần (đặc biệt là ngày thứ Năm chiếm 20,70% số đơn và đỉnh điểm 12 giờ

trưa), trong khi ngày thứ Bảy gần như không phát sinh hóa đơn (0,10 phần trăm). Đồng thời, bảng phân tích hóa đơn hủy df_cancel cho thấy giá trị hàng hủy trả lên tới 1.462.051 Bảng Anh (bằng 7,4% doanh thu dòng bán hàng dương), trong đó có cả những đơn hàng khổng lồ trên 70.000 - 80.000 sản phẩm bị hủy ngược hoàn toàn. Vì bộ dữ liệu không có khóa nối trực tiếp giữa hóa đơn hủy và hóa đơn mua gốc, nhà quản trị cần tránh gọi tổng doanh thu các dòng bán hàng dương là doanh thu thuần sau hoàn trả, mà phải xem tỷ lệ hủy như một chỉ báo rủi ro vận hành cần kiểm soát chặt.

4.3. Hệ thống khuyến nghị có điều kiện và chỉ số đo lường hiệu quả

Trên nguyên tắc mọi đề xuất quản trị rút ra từ phân tích mô tả đều là các khuyến nghị có điều kiện dựa trên dấu hiệu quan sát chứ không phải kết luận nhân quả tất định, nhóm nghiên cứu xây dựng hệ thống sáu nhóm giải pháp hành động cụ thể đi kèm điều kiện áp dụng và bộ chỉ số đo lường hiệu quả sau triển khai (KPI) tại Bảng 4.3. Mỗi giải pháp đều được thiết kế để có thể triển khai thử nghiệm ở quy mô kiểm soát và đánh giá kết quả thực tế trước khi nhân rộng toàn doanh nghiệp.

Phát hiện thực nghiệm từ dữ liệu	Khuyến nghị hành động quản trị có điều kiện	Chỉ số đo lường hiệu quả sau triển khai (KPI)
Doanh thu tháng 9–11 cao gấp 1,74 lần tháng thường; Quý 4 chiếm 35,2% cả năm	Lập kế hoạch nhập hàng và bổ sung nhân sự kho vận thời vụ từ đầu tháng 8 đối với nhóm hàng quà tặng lễ hội, có đối chiếu lịch sử tồn kho thực tế.	Tỷ lệ đứt hàng (Stock-out rate) mùa cao điểm; thời gian xử lý trung bình mỗi đơn hàng; tốc độ tăng trưởng doanh thu Quý 4.
Top 20% khách hàng tạo 77,16% doanh thu; Top 10 khách hàng chiếm 16,2% doanh thu	Thiết lập chính sách quản lý tài khoản trọng điểm (KAM) với chiết khấu theo bậc sản lượng cho 1.353 khách hàng cốt lõi; đồng thời mở rộng tệp khách sỉ vừa để giảm phụ thuộc.	Tỷ lệ duy trì khách hàng VIP (Retention rate); tỷ trọng doanh thu của nhóm khách sỉ mới; mức độ biến động doanh thu khi 1 khách lớn giảm mua.
Top 20% mã sản phẩm tạo ra 77,9% doanh thu; 6 mặt hàng lọt cả Top 10 doanh thu và số lượng	Áp dụng mô hình quản trị tồn kho phân loại ABC ưu tiên dự báo nhu cầu và vị trí kệ lấy hàng nhanh tại kho cho 20% SKU chủ lực sau khi đã kiểm tra biên lợi nhuận gộp.	Số ngày hết hàng của nhóm SKU hạng A; hệ số vòng quay hàng tồn kho (Inventory turnover); thời gian nhặt hàng trung bình tại kho.
Thị trường ngoài UK có AOV trung bình 861,22 £ (gấp đôi UK) nhưng tỷ lệ hủy đơn tới 22,64%	Thử nghiệm gói dịch vụ vận chuyển sỉ tối ưu và quy định mức đặt hàng tối thiểu (MOQ) cho 4 thị trường láng giềng EIRE, Hà Lan, Đức, Pháp sau khi tính đủ chi phí logistics.	Biên lợi nhuận ròng trên mỗi đơn hàng quốc tế sau phí vận chuyển; tỷ lệ đơn hàng quốc tế hoàn tất thành công.
Đơn hàng dồn vào 10:00–15:00 (đỉnh 12:00 trưa) các ngày Thứ Ba – Thứ Năm; Thứ Bảy nghỉ	Bố trí tối đa nhân sự xử lý đơn và băng thông máy chủ vào khung 10:00–15:00 giữa tuần; chuyển lịch bảo trì hệ thống web sang ngày Thứ Bảy hoặc	Năng suất xử lý đơn hàng trên mỗi nhân sự/giờ; thời gian phản hồi hệ thống vào khung 12:00 trưa; thời gian gián đoạn dịch vụ.

(0,1%)	sau 20:00 tối.	
Giá trị hủy đơn lên tới 1.462.051 £ (7,4%); có đơn sỉ 80.995 và 74.215 đv bị hủy ngược hoàn toàn	Bổ sung trường khóa tham chiếu hóa đơn gốc (Original_Invoice_ID) cho mọi hóa đơn C; áp dụng quy trình xác nhận hai lớp và đặt cọc trước khi xuất kho các đơn có Quantity > 1.000.	Tỷ lệ hoàn trả ròng thực tế theo từng đơn gốc; tỷ lệ giảm các vụ hủy đơn sỉ quy mô lớn do nhập sai số lượng; chi phí xử lý hàng hoàn trả.

Bảng 4.3. Khung khuyến nghị quản trị có điều kiện và chỉ số đo lường hiệu quả sau triển khai

4.4. Những giới hạn về dữ liệu và phương pháp luận

Để đảm bảo tính khách quan và chuẩn mực khoa học, báo cáo ghi nhận rõ bảy giới hạn cốt lõi của dữ liệu và phương pháp phân tích đã thực hiện. Thứ nhất, trường mã định danh khách hàng (Customer ID) bị khuyết thiếu ở 243.007 dòng bản ghi (chiếm 22,77 phần trăm tổng số dòng gốc) và sự khuyết thiếu này tập trung chủ yếu ở nhóm khách mua lẻ nội địa Anh; do đó mọi kết luận rút ra từ tập dữ liệu có định danh (df_cust) chỉ phản ánh hành vi của nhóm khách hàng có đăng ký tài khoản và không được phép ngoại suy máy móc cho toàn bộ khách vãng lai. Thứ hai, bộ dữ liệu chỉ phản ánh lịch sử giao dịch của một doanh nghiệp bán lẻ quà tặng duy nhất tại Vương quốc Anh trong giai đoạn 2009-2011, nên các con số cụ thể không đại diện cho mặt bằng thương mại điện tử hiện đại.

Thứ ba, bộ dữ liệu hoàn toàn thiếu vắng thông tin về giá vốn hàng bán (COGS), chi phí vận chuyển thực tế mà doanh nghiệp phải chi trả, chi phí tiếp thị quảng cáo và mức tồn kho đầu kỳ - cuối kỳ; vì vậy nghiên cứu chỉ có thể đánh giá trên chỉ tiêu doanh thu gộp và sản lượng chứ chưa thể tính toán lợi nhuận ròng hay hiệu quả hoàn vốn. Thứ tư, do hệ thống dữ liệu gốc không có khóa liên kết trực tiếp giữa hóa đơn hủy (bắt đầu bằng C) và hóa đơn bán hàng ban đầu, đồng thời quy tắc xóa 34.335 dòng trùng lặp hoàn toàn dựa trên giả định không có hai dòng mặt hàng giống hệt nhau được nhập tách rời trong cùng một hóa đơn, các chỉ số doanh thu và tỷ lệ hủy phụ thuộc trực tiếp vào các quy tắc lọc đã giải trình ở Giai đoạn 2.

Thứ năm, hai trang tính gốc có khoảng thời gian giao nhau từ ngày 01/12/2010 đến ngày 09/12/2010 và kỳ tháng 12/2011 bị cắt cụt ở ngày 09/12/2011; mặc dù quy trình làm sạch đã xử lý triệt để hai điểm này, độ dài chuỗi thời gian hoàn chỉnh chỉ dừng ở 24 tháng nên chưa đủ dài để xây dựng các mô hình dự báo chuỗi thời gian phức tạp. Cuối cùng, toàn bộ nghiên cứu sử dụng phương pháp thống kê mô tả và trực quan hóa khám phá nên chỉ phản ánh mối liên hệ quan sát được trong quá khứ chứ không chứng minh quan hệ nhân quả; mọi khuyến nghị kinh doanh đều cần được kiểm chứng qua thử nghiệm thực tế (A/B testing hoặc triển khai thí điểm) trước khi áp dụng đại trà.

4.5. Kết luận chung và hướng mở rộng nghiên cứu

Tóm lại, thông qua bốn giai đoạn thực nghiệm xuyên suốt từ khảo sát chất lượng dữ liệu gốc, tiền xử lý có giải trình nghiệp vụ, phân tích trực quan hóa đa chiều đến đánh giá tác động quản trị, báo cáo đã xây dựng thành công một quy trình phân tích khoa học dữ liệu minh bạch và có khả năng tái hiện hoàn toàn trên bộ dữ liệu Online Retail II gồm 1.067.371 bản ghi. Giá trị cốt lõi của nghiên cứu không nằm ở

việc chạy theo các thuật toán phức tạp khi dữ liệu chưa cho phép, mà nằm ở sự cẩn trọng trong việc phát hiện vùng chồng lấn 22.523 dòng giữa hai trang tính, chứng minh cơ chế khuyết thiếu phi ngẫu nhiên của 22,77% mã khách hàng, giá lại hợp lý các đơn hàng bán buôn khỏi bộ lọc ngoại lệ IQR và cung cấp hệ thống bằng chứng định lượng xác thực cho 6 quyết định vận hành trọng yếu của doanh nghiệp.

Trong tương lai, nếu doanh nghiệp tích hợp thêm dữ liệu giá vốn hàng bán theo từng mã SKU, bảng phí vận chuyển theo trọng lượng và khu vực địa lý, cùng khóa tham chiếu nối đơn hàng hủy trả với đơn hàng gốc và hệ thống định danh khách hàng thống nhất qua thẻ thành viên hoặc địa chỉ thư điện tử, nghiên cứu có thể mở rộng sang việc phân tích biên lợi nhuận ròng thực chất theo từng thị trường, tính toán giá trị vòng đời khách hàng sau hoàn trả (Net Customer Lifetime Value) và xây dựng hệ thống dự báo nhu cầu tồn kho theo mùa vụ với độ chính xác cao hơn.

DANH MỤC TÀI LIỆU THAM KHẢO

1. *Chen, D., Sain, S. L., & Guo, K. (2012), Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining, Journal of Database Marketing & Customer Strategy Management, Tập 19, Số 3, tr. 197-208.*
2. *UCI Machine Learning Repository (2019), Online Retail II Data Set, Trung tâm Học máy và Hệ thống Thông minh, Đại học California, Irvine, truy cập tại: https://archive.ics.uci.edu/ml/datasets/Online+Retail+II*
3. *Kaggle Dataset Repository (2020), Online Retail II UCI - Transactional data of a UK-based online retail (2009-2011),*
4. *McKinney, W. (2022), Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter (Ấn bản lần thứ 3), Nhà xuất bản O-Reilly Media, Sebastopol, California.*
5. *Pandas Development Team (2025), pandas: Powerful Python data analysis toolkit - Official Documentation, truy cập tại: https://pandas.pydata.org/docs/.*
6. *Hunter, J. D. (2007), Matplotlib: A 2D graphics environment, Computing in Science & Engineering, Tập 9, Số 3, tr. 90–95, tài liệu kỹ thuật tại: https://matplotlib.org/stable/index.html.*
7. *Waskom, M. L. (2021), seaborn: statistical data visualization, Journal of Open Source Software, Tập 6, Số 60, bài 3021, tài liệu kỹ thuật tại: https://seaborn.pydata.org/.*
8. *Virtanen, P. và cộng sự (2020), SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python, Nature Methods, Tập 17, tr. 261–272, tài liệu kỹ thuật tại: https://docs.scipy.org/doc/scipy/.*